FUTUREWAY
KI INSTITUT

Lektion 2: Modellauswahl

Modul 1: KI-Grundlagen

KI Automations Spezialist

Juni 2026

Welche Modellanbieter kennt ihr?

KI-Landschaft 2026

🇺🇸 USA — Spitzenmodelle

OpenAI · Anthropic · Google · Meta · xAI

🇨🇳 China — holt rasant auf

Open Weight: DeepSeek · Qwen · Kimi · GLM

🇪🇺 Europa — setzt auf Souveränität

Mistral · Aleph Alpha · Black Forest Labs



OpenAI (ChatGPT)

- 2015 als gemeinnützige Stiftung in San Francisco gestartet — u. a. von Sam Altman, Elon Musk, Peter Thiel und Reid Hoffman
- Ziel laut Satzung: eine KI entwickeln, die „der gesamten Menschheit nutzt"
- Nach dem Umbau 2025 eine Public Benefit Corp — Microsoft hält noch ~27 %
- Heute mit 852 Mrd. $ bewertet (März 2026), 900 Mio. wöchentliche Nutzer, 50 Mio. zahlend
- Modelle: ChatGPT (LLM), DALL·E (Bild), Sora (Video), GPTs (auf eine Aufgabe zugeschnittenes ChatGPT)
- **Benennung:** Zahl = Generation (GPT-5.5 / 5.6), Stufenname = Leistung — Sol (Flaggschiff), Terra (ausgewogen), Luna (schnell/günstig); Reasoning steckt als einstellbarer „Reasoning Effort" drin (früher eigene o-Serie wie o3 / o4)

Quellen: https://openai.com/index/accelerating-the-next-phase-ai/,https://www.cnbc.com/2025/10/28/open-ai-for-profit-microsoft.html



Google / Gemini (DeepMind)

- DeepMind: KI-Forschungsunternehmen von Google (Alphabet), bekannt für Durchbrüche wie AlphaGo und AlphaFold
- Gemini: Googles multimodales KI-Modell — versteht und erzeugt Text, Bilder, Code, Audio und Video
- Das zentrale KI-Modell von Google, läuft in Search, Workspace und Android — aktuell Gemini 3 / 3.1 Pro
- Jedes erzeugte Bild trägt ein unsichtbares SynthID-Wasserzeichen
- **Benennung:** Gemini mit Stufen Pro (max. Reasoning), Flash (Standard), Flash-Lite (günstig/schnell), Nano (am Gerät); „Deep Think" = Spezial-Reasoning. Bild: Nano Banana (Pro = Qualität, „2" = schnell) & Imagen; Video: Veo; Musik: Lyria

Quelle: https://blog.google/innovation-and-ai/products/nano-banana-pro/,https://techcrunch.com/2026/02/26/google-launches-nano-banana-2-model-with-faster-image-generation/



Anthropic (Claude)

- Unabhängiges KI-Forschungsunternehmen aus den USA, gegründet von ehemaligen OpenAI-Mitarbeitern
- Fokus auf „verantwortungsorientierte" KI: Sicherheit, Interpretierbarkeit und kontrollierbares Verhalten großer Modelle ("Constitutional AI")
- Claude (LLM): Text auf Expertenniveau, analysiert Dokumente, schreibt Code, verarbeitet sehr große Kontexte
- Claude Code: spezialisiertes Werkzeug für Softwareentwicklung (Schreiben, Refaktorieren, Debuggen)
- Seit Mai 2026 das wertvollste KI-Startup der Welt: 965 Mrd. $, IPO eingereicht
- **Benennung:** benannte Größenstufen statt Zahlen — Opus (stärkst), Sonnet (Mitte), Haiku (schnell) + Versionsnummer (z. B. Opus 4.8); Reasoning = Modus „Extended Thinking"; neue Spitzenklasse darüber: Mythos (intern) / Fable (öffentlich)

Quelle: **https://www.aljazeera.com/economy/2026/5/29/anthropic-soars-to-965bn-valuation-leapfrogging-openai**, **https://www.cnbc.com/2026/05/28/anthropic-open-ai-startup-value.html**

Der Fall Fable 5 & Mythos 5

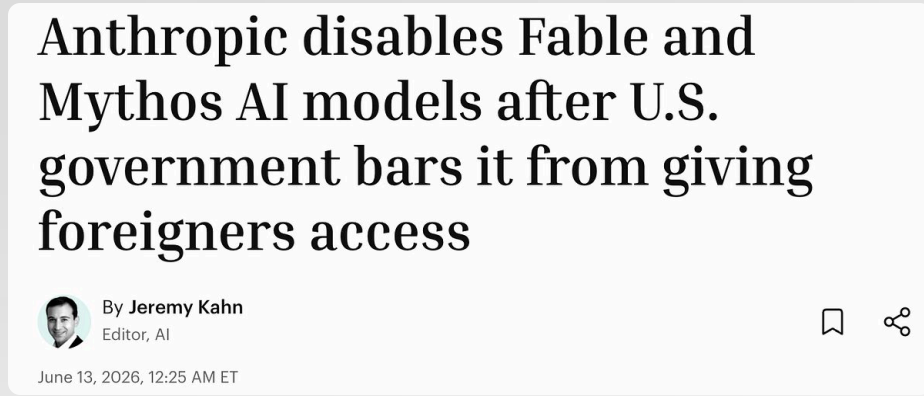
Juni 2026: Das US-Handelsministerium ordnet eine Sperre für alle Ausländer an

Nach Nationalität filtern ist unmöglich → Anthropic schaltet beide weltweit ab

Erster bekannter Fall, in dem ein Live-Modell per Regierungsanordnung vom Netz geht

⚠ **Warum das zählt:** Regulierung kann ein Modell über Nacht abschalten.

Quelle: https://fortune.com/2026/06/13/anthropic-disables-fable-mythos-export-controls-national-security-threat/, https://www.anthropic.com/news/fable-mythos-access



Anthropic disables Fable and Mythos AI models after U.S. government bars it from giving foreigners access

By **Jeremy Kahn**
Editor, AI

June 13, 2026, 12:25 AM ET



Anthropic gegen das US-Militär

Anthropic liefert KI an die Verteidigung

Palantir, 200-Mio.-$-Pentagon-Vertrag, „Claude Gov"

Bedingungen

Keine autonomen Waffen, keine Massenüberwachung

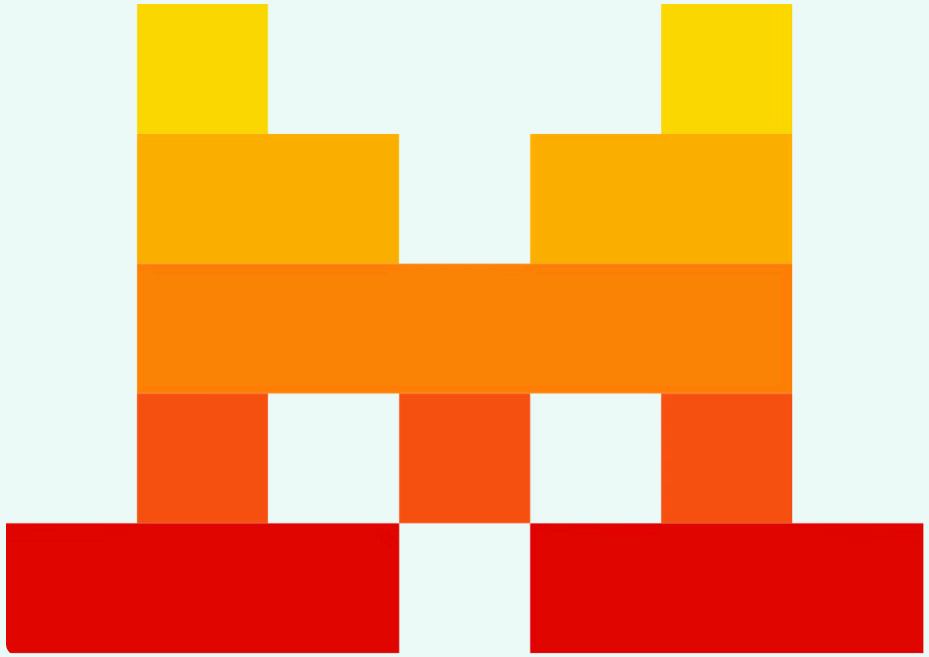
Das Pentagon will uneingeschränkten Zugriff

Anthropic sagt Nein

Die Folge

Die Trump-Regierung setzt Anthropic auf eine Sperrliste

Quelle: https://www.euronews.com/next/2026/02/25/why-ai-company-anthropic-and-the-us-are-at-a-standoff-over-a-military-contract
https://www.cnbc.com/2026/03/04/pentagon-blacklist-anthropic-defense-tech-claude.html



Mistral AI — Europas Nummer 1

- Französisches KI-Start-up, gegründet 2023 von ehemaligen Forschern von Google DeepMind und Meta (Arthur Mensch, Guillaume Lample, Timothée Lacroix)
- Führender europäischer Anbieter offener und kommerzieller KI-Modelle — Open-Source-Philosophie plus moderne Technik
- Modelle via Cloud/API oder selbst gehostet — maximale Kontrolle über Daten und Infrastruktur
- Bewertung ~11,7 Mrd. € (neue Runde Richtung 20 Mrd. € im Gespräch); Chatbot jetzt „Vibe"
- **Benennung:** Größen Large / Medium / Small / Ministral (Edge); Spezialmodelle mit „-stral": Magistral (Reasoning), Devstral (Coding-Agent), Codestral (Code), Pixtral (Bild), Voxtral (Audio), OCR (Dokumente) — 2026 teils in ein Modell mit umschaltbarem Reasoning verschmolzen

Quelle: https://mistral.ai/about/, https://techcrunch.com/2026/06/12/mistral-is-rumored-to-be-raising-e3b-at-e20-valuation/

Aleph Alpha — Souveränität made in Germany

- Deutsches KI-Unternehmen mit Sitz in Heidelberg, gegründet 2019
- Fokus auf Unternehmen und öffentliche Institutionen — Augenmerk auf Daten-Souveränität, Datenschutz und europäische Regulierung
- PhariaAI: komplett steuerbare KI-Infrastruktur (on-premise, DSGVO-konform) statt „Black-Box"-Lösungen
- Kunden: Bund, Bundeswehr, Schwarz-Gruppe — April 2026 Fusion mit Cohere (~20 Mrd. $)
- **Benennung:** kaum Consumer-Modellnamen — im Zentrum die Plattform „PhariaAI" und die Modellreihe „Pharia" (früher Luminous); es geht um Infrastruktur, nicht um einzelne Chat-Modelle

Quelle: https://aleph-alpha.com/phariaai/, https://innfactory.ai/en/ai-models/aleph-alpha-luminous/

ALEPH ALPHA

Meta (Llama) — Open Weight

- Familie großer Sprachmodelle, von Meta AI ab Februar 2023 veröffentlicht
- Offen verfügbar (Open Weight): frei zugängliche Gewichte — selbst hosten, modifizieren, für eigene Anwendungen einsetzen
- Strategie: Ökosystem (AWS, Azure, Google Cloud) statt einer eigenen API
- Open Weight heißt: anpassbar — aber nicht 100 % Open Source
- **Benennung:** Llama + Generation (Llama 4); Mitglieder mit Tarnnamen — Scout (effizient, 10 Mio. Token Kontext), Maverick (stärker), Behemoth (Größtmodell, noch im Training). Früher reine Parametergrößen wie 8B / 70B / 405B

Quelle: https://ai.meta.com/blog/llama-4-multimodal-intelligence/





DeepSeek — der China-Schock

- 2023 gegründetes chinesisches KI-Startup mit Sitz in Hangzhou — finanziert vom Hedgefonds High-Flyer, geführt von Liang Wenfeng
- Entwickelt offene, effiziente Sprachmodelle: Leistung auf Augenhöhe mit führenden westlichen Modellen, bei deutlich weniger Rechenaufwand
- Ziel: Hochleistungs-KI demokratisieren — niedrige Kosten, offene Modelle, geringer Hardwarebedarf
- Anfang 2025 ließ R1 sogar die Nvidia-Aktie einbrechen; Achtung: bei politisch heiklen Fragen wird gefiltert
- **Benennung:** „V" = allgemeines Basismodell (V3 → V3.2 → V4), „R" = Reasoning (R1); neuere V-Modelle haben den Denkmodus eingebaut. Open Weight (meist MIT-Lizenz)

Quelle: https://fortune.com/2025/01/27/deepseek-founder-liang-wenfeng-hedge-fund-manager-high-flyer-quant-trading/, https://www.bentoml.com/blog/the-complete-guide-to-deepseek-models-from-v3-to-r1-and-beyond

China im Überblick

Qwen (Alibaba)

Beste mehrsprachige Open-Weight-Modelle

Kimi (Moonshot)

Überzeugt bei Agent-Swarm-Orchestrierung

MiniMax

Multimodale KI-Modelle

GLM (z.ai / Zhipu)

Trainiert komplett ohne Nvidia, auf Huawei-Chips

China hält vier der Top-5-Plätze bei Open-Weight-KI

Quelle: **https://www.buildfastwithai.com/blogs/qwen-3-6-plus-vs-glm-5-1-vs-kimi-2-5-coding-2026** Quelle: **https://www.remoteopenclaw.com/blog/best-chinese-models-2026**

Chinas Open-Source-Offensive

- DeepSeek R1 (Jan. 2025) war der Wendepunkt: chinesische Modelle erreichen Top-Niveau zu einem Bruchteil der Kosten
- Kimi K2.5 (Moonshot) reicht in Benchmarks nah an Claude Opus heran
- Strategie mit Staatsförderung: offene Modelle für technologische Autarkie und breite Industrie-Anwendung
- Alibaba, Tencent und Baidu stellen Modelle offen auf Hugging Face — bei den Downloads weltweit führend (Stanford HAI)
- Folge: westliche Firmen bauen auf chinesischen Modellen auf → Preisdruck auf OpenAI & Anthropic, NVIDIA-Abhängigkeit in Frage gestellt
- Kehrseite: Zensur und politische Einflussnahme bei heiklen Themen

Für Europa: Chance, mit effizienteren, transparenten und spezialisierten Modellen (z. B. Medizin, Recht) aufzuholen.

Quelle: https://www.mind-verse.de/news/chinesische-open-source-ki-modelle-auswirkungen-globaler-markt





xAI (Grok) + SpaceX

Feb. 2026: SpaceX übernimmt xAI

Die größte Privatfusion aller Zeiten (1,25 Bio. $)

Juni 2026: SpaceX-Börsengang

~75 Mrd. $ eingesammelt → größter IPO der Geschichte

Schattenseite

Modelle mit wenigen Einschränkungen → Diskriminierung und Missbrauch

Benennung: Grok + Version (4 / 4.1 / 4.3)

„Heavy" = stärkste Reasoning-Stufe (mehrere Agenten parallel), „Fast" = schnelle Variante; Bild & Video: Grok Imagine

Quelle: https://www.cnbc.com/2026/02/03/musk-xai-spacex-biggest-merger-ever.html
Quelle: https://intellectia.ai/blog/spacex-ipo-2026-investment-analysis Quelle: https://www.npr.org/2025/07/09/nx-s1-5462609/grok-elon-musk-antisemitic-racist-content

NVIDIA — der Gigant dahinter

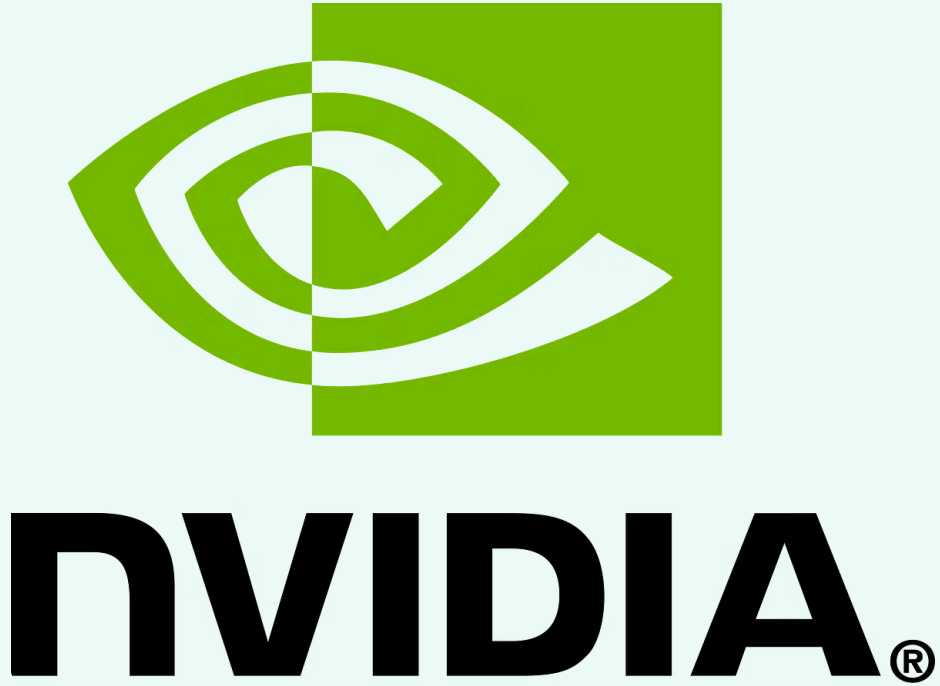
Fast jedes große Modell wird auf NVIDIA-GPUs trainiert

Okt. 2025: erstes 5-Billionen-$-Unternehmen der Welt

Fängt an, eigene Modelle zu bauen

Benennung: LLM-Reihe „Nemotron" in Größen Nano / Super / Ultra

Quellen: https://ai-frontiers.org/articles/exporting-nvidia-chipa-is-bad-for-us, https://tradersunion.com/news/financial-news/show/2472247-nvidia-china-chip-export-controls/



Spezialisten für Bild, Ton & Video

Midjourney

Schönste Bilder, profitabel, ganz ohne Investoren

Black Forest Labs (DE)

FLUX.2 — Foto-Realismus aus Freiburg

ElevenLabs

Sprach-KI, Marktführer (11 Mrd. $)

Runway

KI-Video & „World Models"

Suno

KI-Musik

ByteDance

Video

Quelle: https://techcrunch.com/2026/02/04/elevenlabs-raises-500m-from-sequioia-at-a-11-billion-valuation/, https://techcrunch.com/2026/02/10/ai-video-startup-runway-raises-315m-at-5-3b-valuation-eyes-more-capable-world-models/, https://techcrunch.com/2025/12/01/black-forest-labs-raises-300m-at-3-25b-valuation/

Perplexity — die Antwortmaschine

- 2022 gegründete KI-gestützte Such- und Antwortmaschine mit Sitz in San Francisco
- Kombiniert Websuche mit LLMs: durchsucht das Internet in Echtzeit und liefert eine zusammengefasste Antwort mit Quellenangaben
- Anders als klassische Suchmaschinen: beantwortet Fragen direkt in natürlicher Sprache, statt nur Links zu zeigen
- **Benennung:** eigenes Modell heißt „Sonar" (Websuche + generative KI); im Pro-Tarif sind fremde Modelle wählbar (GPT, Claude, Gemini) — Perplexity ist eher Plattform als eigene Modellfamilie

Quelle: **https://www.gradually.ai/perplexity-statistiken/**, **https://www.getpanto.ai/blog/perplexity-ai-statistics**

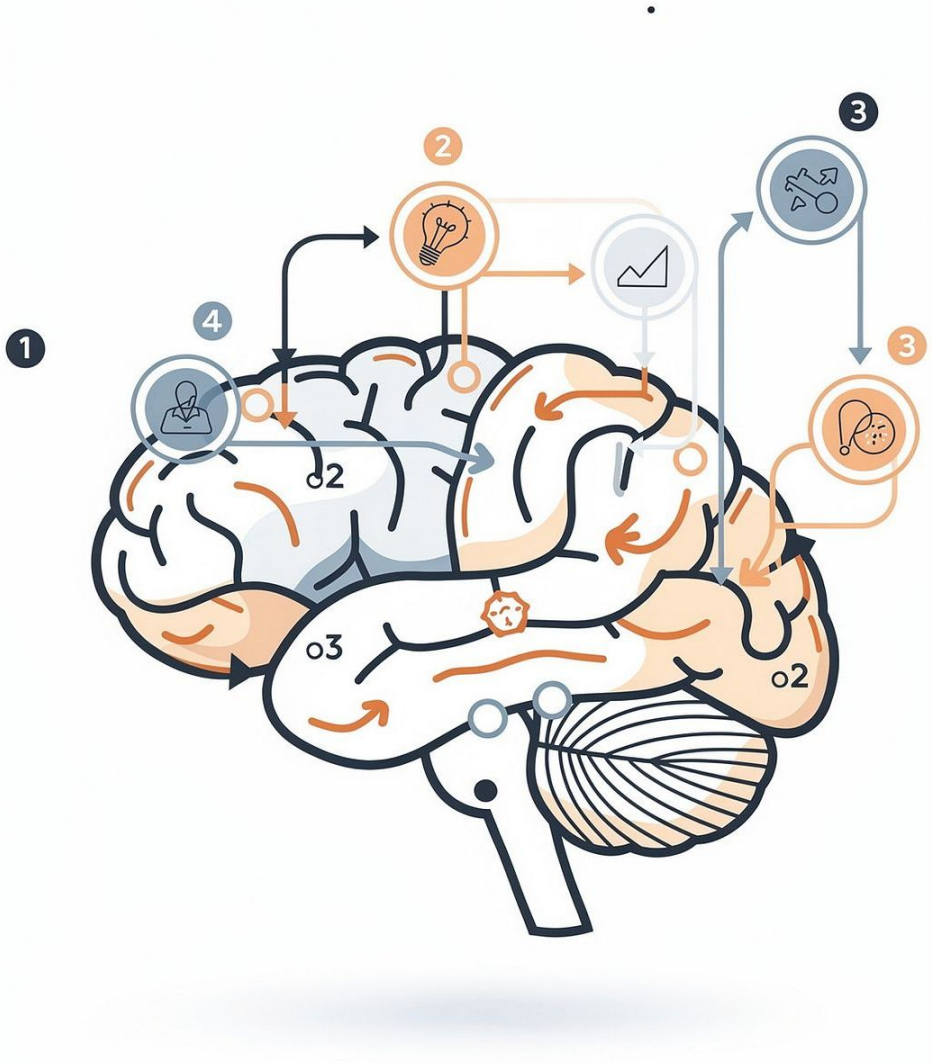


Modellnamen entschlüsseln

Die meisten Namen folgen vier Bausteinen:

1	**Generation = Zahl / Version** GPT-5.6, Gemini 3, Llama 4, Qwen3.6, Grok 4
2	**Größe & Leistung = Stufenname** Opus/Sonnet/Haiku · Pro/Flash/Lite · Large/Medium/Small · Sol/Terra/Luna · Scout/Maverick/Behemoth
3	**Fähigkeit = Zusatz / Suffix** -VL (Bild), -Coder / Codestral (Code), -Omni (alles), DALL·E / Sora / Veo (Bild & Video)
4	**Reasoning = eigener Modus oder eigenes Modell** „Extended Thinking", „Reasoning Effort", o-Serie, R1, QwQ, Magistral, Grok Heavy

Daumenregeln: „mini / nano / lite / flash / turbo / schnell" = kleiner, schneller, günstiger. MoE-Schreibweise „235B-A22B" = Gesamt- / aktive Parameter.



Reasoning-Modelle — was & warum

Normale LLMs antworten sofort.

Reasoning-Modelle denken erst Schritt für Schritt.

Stark bei

Mathe, Code, Analyse, Planung

Schwach bei

Einfachen Aufgaben — da nur langsamer und teurer

Gute Reasoning-Modelle

OpenAI o-Serie, DeepSeek R1, Gemini Thinking, Claude Extended Thinking, Grok Heavy

Faustregel: harte Denkaufgabe → Reasoning. Alles andere → schnelles Modell.

Quelle: https://medium.com/@mayadakhatib/the-era-of-reasoning-models-moving-beyond-chain-of-thought-prompting-fa24ce25c106

Benchmarks & Rankings

Viele Tests sind „gesättigt"

Alle liegen über 90 %

„Benchmaxxing"

Anbieter trainieren gezielt auf den Test

Labor ≠ Realität

Eine Zahl sagt wenig über deinen Anwendungsfall

Vergleichen kannst du auf

LMArena und Artificial Analysis

Schwer zu tricksen

ARC-AGI, Humanity's Last Exam, SWE-bench (Code)

Rankings: arena.ai | artificialanalysis.ai

Merke: nie nur einer einzigen Zahl glauben.

Quellen: https://kili-technology.com/blog/ai-benchmarks-guide-the-top-evaluations-in-2026-and-why-theyre-not-enough, https://nanonets.com/blog/ai-benchmarks-explained-gpqa-swe-bench-chatbot-arena/, https://www.ibm.com/de-de/think/topics/llm-benchmarks

Das richtige Modell wählen

01

Reasoning nötig?

ja / nein

02

Input

Text, Bild, Audio, Video?

03

Output

Text, Bild, Stimme, Video?

04

Kontextfenster

Wie viel Text passt rein?

05

Kosten

Gratis, API-Preis oder selbst hosten?

06

Tempo

Echtzeit oder egal?

07

Datenschutz

Cloud, EU-souverän oder selbst gehostet?

08

Lizenz

Open Weight oder proprietär?

09

Deutsch

Wie gut beherrscht es die Sprache?

Tipp: die kleinste Option nehmen, die den Job zuverlässig erledigt.

Am Ende selbst ausprobieren und nach persönlicher Einschätzung entscheiden.

Und: am Ende selbst ausprobieren und nach persönlicher Einschätzung entscheiden.

Aufgabe: Modellauswahl

Für zehn praxisnahe Use Cases aus Vertrieb, Marketing, E-Commerce, Logistik und HR sollt ihr jeweils das passende KI-Modell (oder eine sinnvolle Kombination) auswählen — und eure Wahl begründen.

Es gibt selten nur eine richtige Antwort. Wichtig ist die Begründung. Ihr könnt alle Modelle auswählen, die euch in Langdock zur Verfügung stehen. Darüber hinaus könnt ihr noch andere Modelle, Anbieter oder spezialisierte Tools vorschlagen, wenn der Use Case das erfordert. Begründet dann, warum Langdock allein nicht reicht.

Beispiel

Aus einem langen Meeting-Transkript (deutsch, ~20 Seiten) soll eine **Zusammenfassung mit nächsten Schritten** entstehen. Die Notizen enthalten **Namen echter Ansprechpartner**.

Use-Case	Modellvorschlag	Begründung
Zusammenfassung Meeting-Transkript	• Claude Sonnet 4.6 (in Langdock). • Alternative: Gemini 3.1 Pro (bei sehr langem Transkript).	• Gutes Deutsch, stark im Zusammenfassen, großer Kontext — Reasoning nicht nötig, also kein teures Top-Modell. • Datenschutz: Personenbezug vorhanden → über Langdock (EU, AVV) vertretbar. Bei sehr sensiblen Inhalten besser Mistral Large 3 (EU-Anbieter).
…	…	…

Use Cases

Vertrieb

1. Lead-Recherche & Briefing Zu jedem neuen CRM-Lead soll automatisch ein kurzes Briefing entstehen: Branche, Unternehmensgröße, mögliche Use Cases, aktuelle News zum Unternehmen. Variation: Die News müssen aktuell sein (Echtzeit-Web), und es laufen täglich mehrere hundert Leads durch.
2. Personalisierte Vertriebs-E-Mails Aus Gesprächsnotizen und CRM-Daten sollen personalisierte Follow-up-E-Mails auf Deutsch entstehen, im Ton zur jeweiligen Zielperson passend. Variation: Die Notizen enthalten Namen, Kontaktdaten und Gesprächsinhalte echter Ansprechpartner (personenbezogene Daten).

Marketing

1. SEO-Blogartikel in der Markenstimme Längere deutschsprachige Blogartikel (1.500+ Wörter), SEO-optimiert und konsistent in der definierten Markensprache. Variation: Es werden viele Artikel pro Woche gebraucht — Qualität soll hoch bleiben, die Kosten aber im Rahmen.
2. Kampagnen-Visuals mit Text im Bild Für eine Social-Media-Kampagne werden Bilder gebraucht, in denen lesbarer deutscher Text (Claims, Rabatte) sauber im Bild sitzt. Variation: Eine Variante soll markenkonform und ohne Cloud-Abhängigkeit möglich sein (Datensouveränität, eigene Infrastruktur).

E-Commerce

1. Produktbeschreibungen in Masse Für 20.000 Artikel sollen Produktbeschreibungen erzeugt werden — in mehreren Sprachen, in gleichbleibender Struktur. Variation: Hier zählen vor allem Skalierung, Tempo und Kosten pro Beschreibung.
2. Kundenservice-Chatbot (Retouren & Bestellungen) Ein Chatbot beantwortet Kundenanfragen in Echtzeit, greift dabei auf FAQ und Produktdaten zu (RAG). Variation: Der Bot verarbeitet Bestell- und Adressdaten der Kund:innen und muss schnell antworten.

Logistik

1. Dokumentenextraktion (Lieferscheine & Rechnungen) Aus eingescannten Lieferscheinen, Rechnungen und Zolldokumenten sollen strukturierte Daten (Positionen, Mengen, Beträge) extrahiert werden. Variation: Der Input sind Bilder/Scans, kein sauberer Text — und die Dokumente enthalten teils personenbezogene Daten.
2. Tourenplanung & Was-wäre-wenn-Analyse Ein Planungsteam will Optimierungs-Szenarien für Liefertouren durchdenken, Trade-offs verstehen und passende Auswertungs-/Code-Logik entwerfen. Variation: Die Aufgabe verlangt mehrstufiges, logisches Durchdenken — und es stellt sich die Frage, ob ein Sprachmodell hier überhaupt das richtige Werkzeug ist.

HR

1. Bewerber-Screening & CV-Matching Lebensläufe sollen analysiert und gegen ein Stellenprofil gematcht werden, inklusive Kurzbegründung pro Kandidat:in. Variation: Es geht um vollständige Bewerberunterlagen (hochsensible personenbezogene Daten) — und der Einsatzbereich gilt unter dem EU AI Act als heikel.
2. HR-Self-Service-Assistent Ein interner Assistent beantwortet Mitarbeiterfragen zu Urlaub, Spesen und Richtlinien, gestützt auf interne HR-Dokumente (RAG). Variation: Alltagswerkzeug für viele Mitarbeitende — Kosten und Tempo zählen, interne Dokumente und teils Personenbezug sollen die EU nicht verlassen.

Lösungsvorschlag

Die folgende Tabelle präsentiert mögliche KI-Modellvorschläge für eine Reihe von praxisnahen Anwendungsfällen. Die Begründungen legen dar, warum ein bestimmtes Modell oder eine Kombination dafür am besten geeignet ist, wobei Faktoren wie Leistungsfähigkeit, Kosten, Geschwindigkeit und Datenschutz berücksichtigt werden.

Use-Case	Modellvorschlag	Begründung
Vertrieb: Lead-Recherche & Briefing	• Gemini 3.1 Pro (o. GPT-5.5) mit Web-Suche. • Alternative: günstiges Modell (Gemini 3 Flash / DeepSeek v3.1) für die Masse, im Workflow.	• Echtzeit-News nötig + viele Leads/Tag → günstig vorrecherchieren, stark verdichten. • Datenschutz: unkritisch (öffentliche Firmendaten).
Vertrieb: Personalisierte E-Mails	• Claude Sonnet 4.6 oder Mistral Large 3. • Alternative: GPT-5.4 für mehr Stil-Variation.	• Sprachqualität/Ton (Deutsch) entscheidet, Reasoning unnötig. • Datenschutz: Kontaktdaten → über Langdock (EU, AVV) ok; strenger: Mistral (EU). Datensparsamkeit.
Marketing: SEO-Blogartikel in Markenstimme	• Claude Sonnet 4.6. • Alternative: Gemini 3 Flash / DeepSeek v3.1 für Entwürfe, Feinschliff durch starkes Modell.	• Qualität vs. Kosten bei vielen Artikeln → zweistufig + zentrale Prompt-/Skill-Bibliothek. • Datenschutz: unkritisch.
Marketing: Kampagnen-Visuals mit Text im Bild	• Bildmodell nötig: Nano Banana Pro (Gemini 3 Pro Image). • EU-souverän: FLUX.2 (selbst hostbar).	• Output = Bild mit lesbarem Text; reines LLM scheidet aus. • Souveränität: FLUX self-hosted = ohne Cloud. Liegt außerhalb Langdock-Chat.
E-Commerce: Produktbeschreibungen in Masse	• Günstig & schnell: Gemini 3 Flash / DeepSeek v3.1 / Llama 4 Maverick im Workflow. • Alternative: Mistral Large 3 für saubere Mehrsprachigkeit.	• Kosten & Tempo × 20.000 entscheiden; Reasoning unnötig. • Datenschutz: unkritisch.
E-Commerce: Kundenservice-Chatbot	• Schnell + RAG: Claude Haiku 4.5 / Gemini 3 Flash. • Alternative: Claude Sonnet 4.6 für schwierige Fälle + Eskalation.	• Echtzeit (Latenz) + Dauerbetriebskosten. • Datenschutz: Bestell-/Adressdaten → Langdock (EU, AVV), nur nötige Daten übergeben.
Logistik: Dokumentenextraktion (Scans)	• Multimodal: Gemini 3.1 Pro oder Mistral OCR (EU). • Alternative: Claude für Extraktion → JSON.	• Input = Scan/Bild → reines Text-LLM scheidet aus. • Datenschutz: Personenbezug → Mistral OCR (EU) sauberer.
Logistik: Tourenplanung & Was-wäre-wenn	• Reasoning-Modell: o3 Pro / GPT-5.5 / Claude Opus 4.7 / Gemini 3.1 Pro. • Echte Optimierung: klassischer Solver (z. B. OR-Tools).	• Mehrstufige Logik → Reasoning fürs Strukturieren, Erklären, Code. • „Nicht für alles ein LLM": Rechnen gehört in den Solver. Datenschutz meist unkritisch.
HR: Bewerber-Screening & CV-Matching	• EU / self-hosted: Mistral Large 3 oder selbst gehostetes Modell. • Keine US-Cloud.	• Hochsensible Daten + EU-AI-Act-Hochrisiko → Datenschutz schlägt Leistung; Mensch entscheidet final. • Zeigt: „bestes Modell ≠ stärkster Benchmark".
HR: Self-Service-Assistent	• Günstig + RAG, EU-gehostet: Mistral Large 3 (o. EU-geroutet); streng: self-hosted. • Alternative: Claude Haiku 4.5 / Gemini 3 Flash (EU, AVV), wenn unkritisch.	• Kosten/Tempo im Alltag + EU-Verbleib interner Dokumente. • Datenschutz: Zugriffsrechte sauber setzen.

Aufgabe: ABC-Analyse E-Commerce

Erstelle eine ABC-Analyse und XYZ-Analyse zur Optimierung deines Produktportfolios im Online-Shop. Nutze dazu Langdock (GPT-5.5 und Opus 4.8 mit jeweils Thinking aktiviert und nutze zusätzlich o4 mini und Haiku 4.5).
Die Anleitung dazu findest du unter diesem Link: **ABC-Analyse berechnen: Anleitung, Formel und Beispiel - Shopify Deutschland**

Entwickle einen Prompt und nutze den gleichen Prompt für alle Modelle.
Was fällt dir auf? Gibt es Unterschiede?

Hinweis: hänge die CSV mit den Bestellungen als Anhang im Chat an.
Zusatz: nutze weitere Modelle und vergleiche die Ergebnisse. Außerdem kannst du Handlungsempfehlungen für das Produktmanagement und Marketing ableiten.

File upload

contoso_bike_shop_bestellungen.csv

15.6 MB

