FUTUREWAY
KI INSTITUT

Modul 1: KI-Grundlagen

Lektion 3: LLMs unter der Lupe

KI Automations Spezialist

Juni 2026

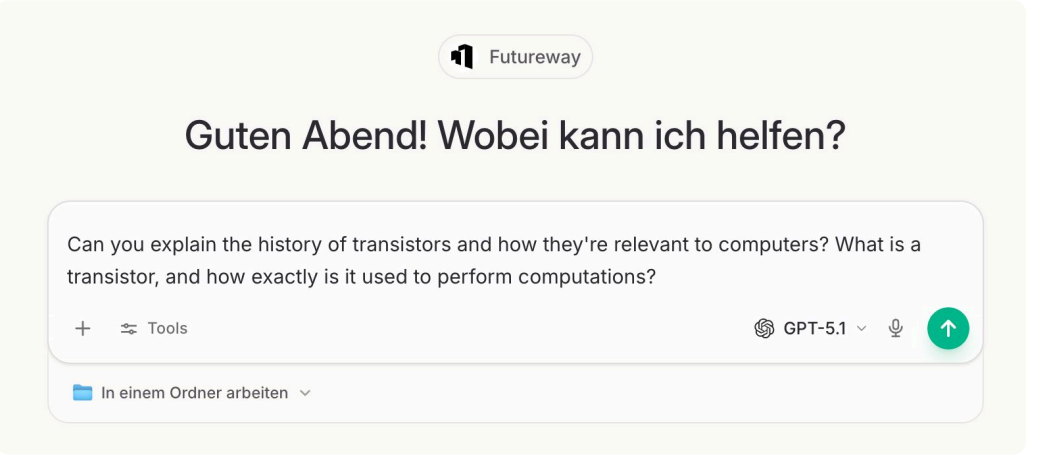
Was passiert eigentlich im Hintergrund, wenn du bei Langdock eine Anfrage stellst?

1. Die Anfrage

Was passiert hier?

Du gibst eine Nachricht in einer **Web-App (Browser)** oder **Mobile App** eines KI-Anbieters ein.

> Du siehst nur die Nutzeroberfläche. Die eigentliche "Intelligenz" passiert woanders.
>
> Deine Nachricht verlässt dein Endgerät und geht ins Internet.



2. Transport der Anfrage

Wie kommt deine Nachricht ins Rechenzentrum?

1. Dein Endgerät sendet die Anfrage ins Internet.
2. Die Anfrage wird über HTTPS / SSL verschlüsselt (also geschützt vor fremdem Zugriff) übertragen.
3. Sie landet beim Modellanbieter (OpenAI, Google, Anthropic, ...)

> SSL / HTTPS = sichere Datenübertragung über das Internet
>
> Request = Fachbegriff für Anfrage in "IT-Sprech"

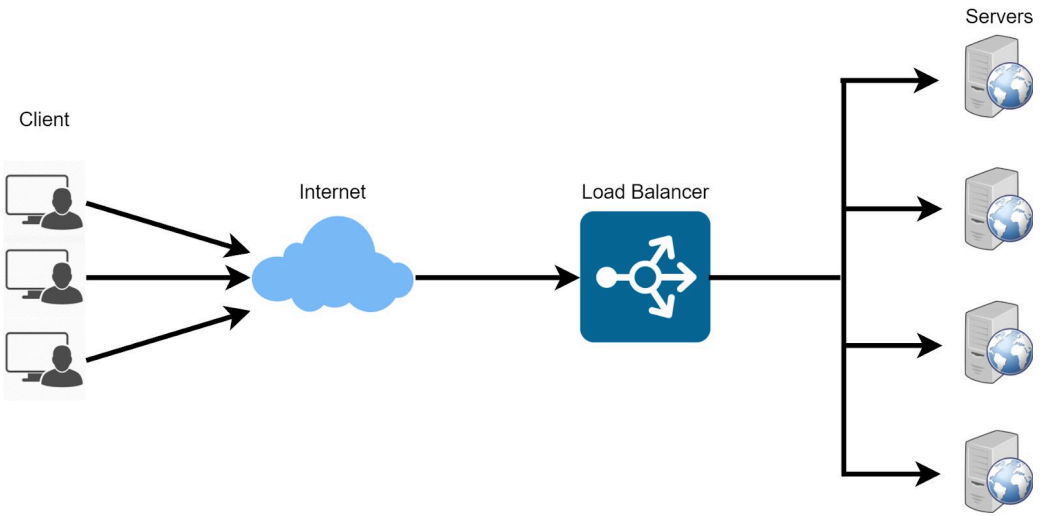


3. Load Balancer

Was macht ein Load Balancer?

Er verteilt alle eingehenden Anfragen auf freie Server.
Vergleich: Weichenstellwerk an einem Bahnhof

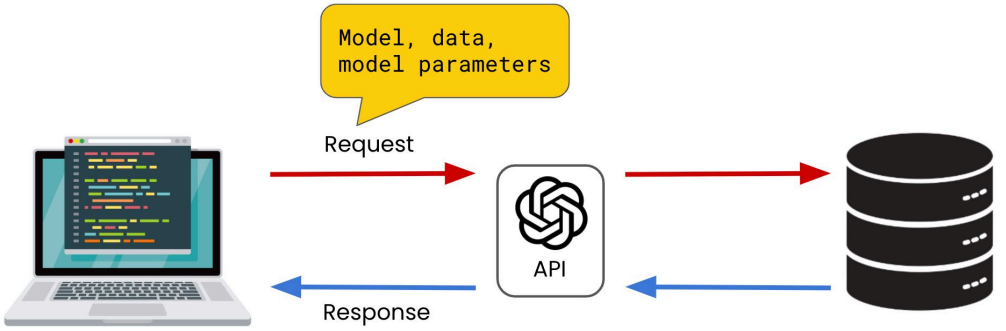
> Ohne Load Balancer würde die Infrastruktur überlastet werden.
> Millionen Nutzer wollen gleichzeitig zugreifen.
> Deshalb braucht es einen geregelten Ablauf.



4. Schnittstelle - API

Was macht eine API?

- Sie leitet deine Anfrage an das richtige KI-Modell weiter.
- Sie übersetzt deine Anfrage in ein Format, das das KI-Modell versteht.
- Sie empfängt die Antwort des KI-Modells und leitet es weiter.



Eine **API** (Application Programming Interface) ist eine Schnittstelle, über die dein Gerät mit der KI sprechen kann.

5. Rechenzentrum

Was ist ein Rechenzentrum?

- Hier laufen die LLMs (z. B. GPT-5.5, Opus 4.8, ...)
- Ein Gebäude voller Hochleistungsserver

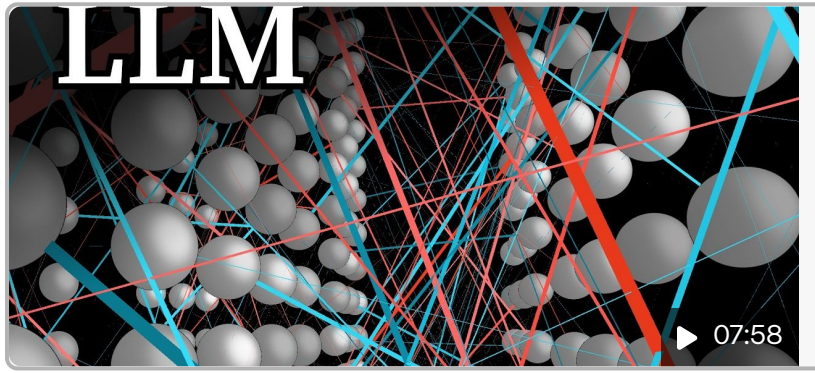
Was passiert dort?

1. Server empfängt deine Anfrage
2. Kontext zusammenbauen
3. Tokenisierung (auf CPU)
4. Laden in den GPU speicher
5. Vektorisierung (Embedding) → semantische Einordnung durch Zahlen (Vektoren)
6. Verarbeitung der Anfrage auf speziellen KI-Chips (GPUs / TPUs)
7. Token für Token wird nacheinander berechnet und über die API ausgegeben (oft als Stream, also live nacheinander).
8. Wenn die Anfrage abgeschlossen ist, wird der Cache der GPU geleert für Anfragen anderer User.

ⓘ Eine **API** (Application Programming Interface) ist eine Schnittstelle, über die dein Gerät mit der KI sprechen kann.



LLMs erklärt

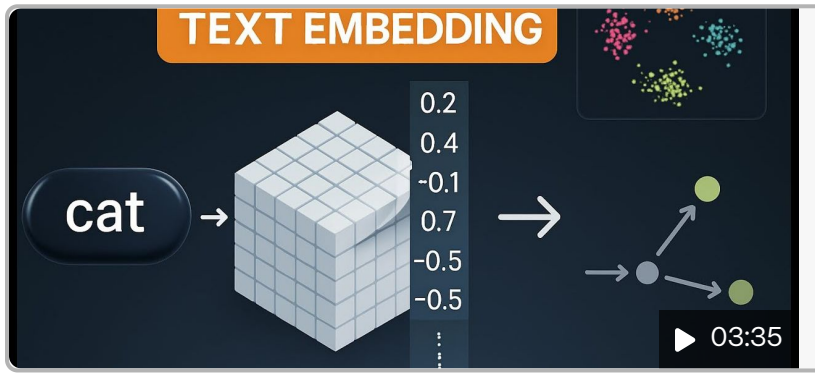


YouTube

Large Language Models explained briefly

A light intro to LLMs, chatbots, pretraining, and transformers. Dig deeper here: https://www.youtube.com/playlist?list=PLZHQObOWTQDNU6R1_67000Dx_ZCJB-...

Vektoren und semantische Ähnlichkeit



YouTube

How AI Turns Words Into Vectors: Embeddings

Ever wondered how a computer learns the meaning of words like king and queen? How does an AI know that king is more related to queen than it is to apple? This vide...