FUTUREWAY
KI INSTITUT

# Modul 1: KI-Grundlagen

## Lektion 4: RAG – Retrieval Augmented Generation

**KI Automations Spezialist**

August 2026

# Woher kennt eine KI die richtige Antwort?

Künstliche Intelligenzen beziehen ihre Informationen aus verschiedenen Quellen. Ordnen Sie die folgenden Aussagen den möglichen Ursprüngen zu:

### Aus dem Modelltraining

Basiswissen und Muster, die während des Trainings gelernt wurden.

### Aus dem aktuellen Gespräch

Kontext und Details, die direkt vom Benutzer eingegeben werden.

### Aus bereitgestellten Dokumenten

Informationen aus speziell zur Verfügung gestellten Texten oder Datenbanken.

### Aus einer Websuche

Echtzeit-Informationen, die durch eine aktive Suche im Internet abgerufen werden.

### Aus verbundenen Systemen

Daten aus externen Anwendungen oder internen Geschäftssystemen.

### Beispiele zur Einordnung:

> „Berlin ist die Hauptstadt Deutschlands.“
>
> „Unser Professional-Tarif kostet 89 Euro.“
>
> „Der aktuelle Lagerbestand beträgt 42 Stück.“

# Ein Sprachmodell kennt unser Unternehmen nicht

### Das Modell kennt möglicherweise:

- allgemeine Vertriebsbegriffe
- typische Marketingmethoden
- öffentlich bekannte Informationen
- allgemeine Formulierungen

### Das Modell kennt nicht automatisch:

- unsere aktuellen Preise
- interne Rabattregeln
- neue Produktfunktionen
- Vertragsbedingungen
- Kundendaten und Prozesse




> „Was kostet unser Professional-Tarif?"
>
> Ohne bereitgestellte Quelle kann die KI den korrekten Preis nicht zuverlässig kennen.

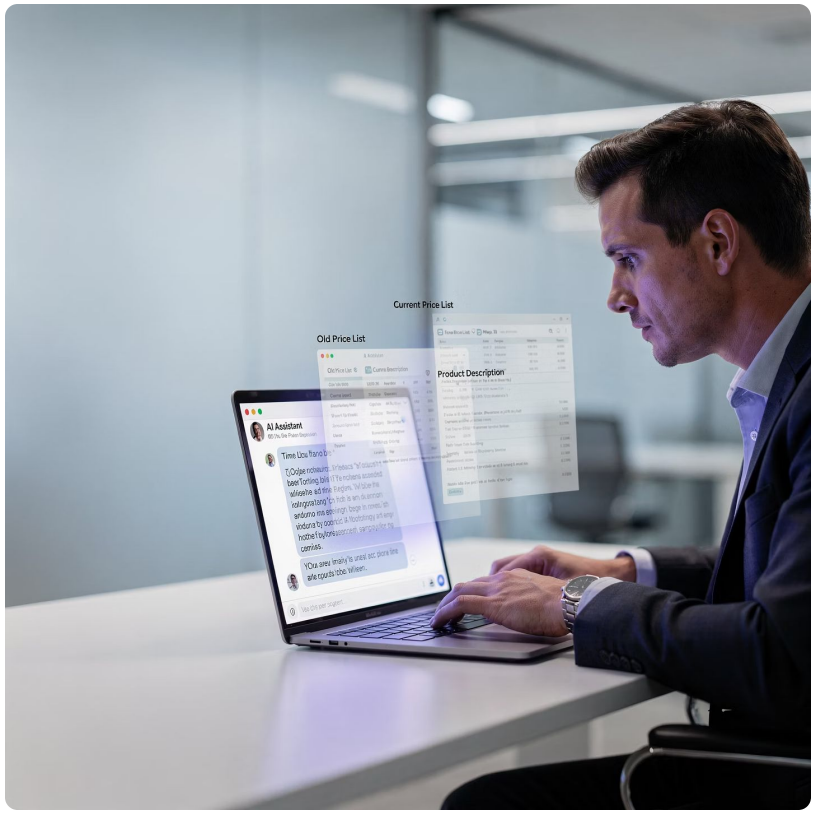
# Überzeugend bedeutet nicht richtig

### 💬 Nutzerfrage

„Was kostet SalesFlow Professional und welche Vorteile bietet der Tarif?"

### 🤖 KI-Antwort

„SalesFlow Professional kostet **79 Euro monatlich**. Der Tarif ist **jederzeit monatlich kündbar** und enthält eine **direkte SAP-Integration**. Zusätzlich profitieren Unternehmen von einer **garantierten Umsatzsteigerung**."



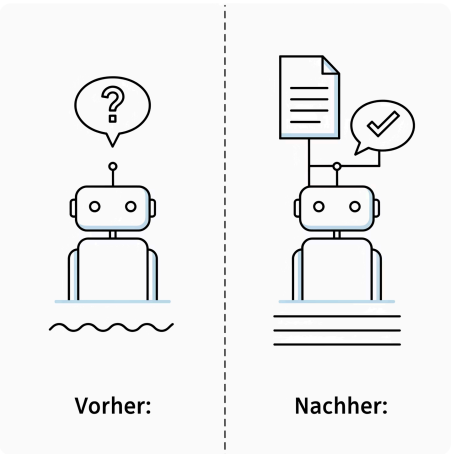

| Aussage | Problem |
|---|---|
| 79 Euro monatlich | möglicherweise veralteter Preis |
| jederzeit kündbar | möglicherweise falscher Tarif |
| direkte SAP-Integration | nicht belegt |
| garantierte Umsatzsteigerung | erfundenes Leistungsversprechen |

⚠ **„Die Antwort klingt professionell – aber keine der Aussagen wurde überprüft."**

Plausibel formuliert ≠ durch Quellen belegt

# Kontext verbessert die Antwort

Ohne Kontext liefert eine KI ungenaue Antworten – mit dem richtigen Dokument wird sie präzise.




### Ohne Kontext

„Was kostet unser Professional-Tarif?"

Ausweichende Antwort – keine internen Daten verfügbar.

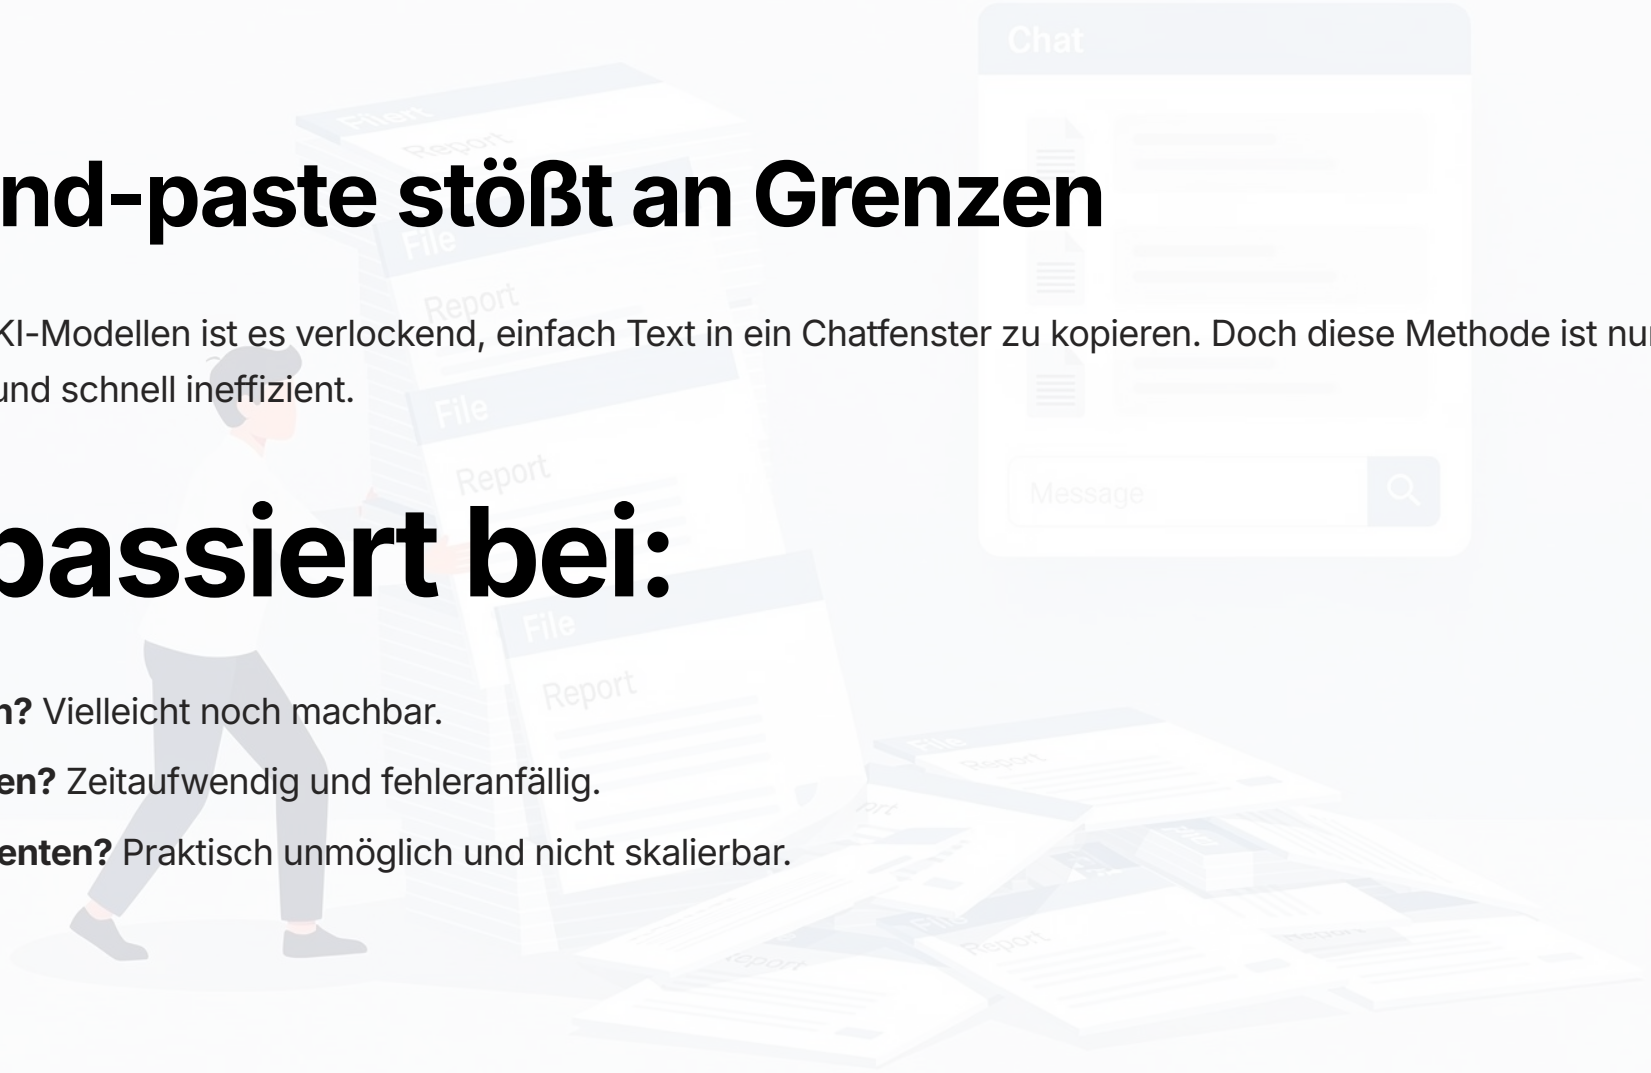
### Mit Kontext

„Professional kostet 89 Euro pro Nutzer und Monat."

Präzise Antwort aus bereitgestelltem Dokument.

# Copy-and-paste stößt an Grenzen

Beim Umgang mit KI-Modellen ist es verlockend, einfach Text in ein Chatfenster zu kopieren. Doch diese Methode ist nur für kleine Mengen geeignet und schnell ineffizient.

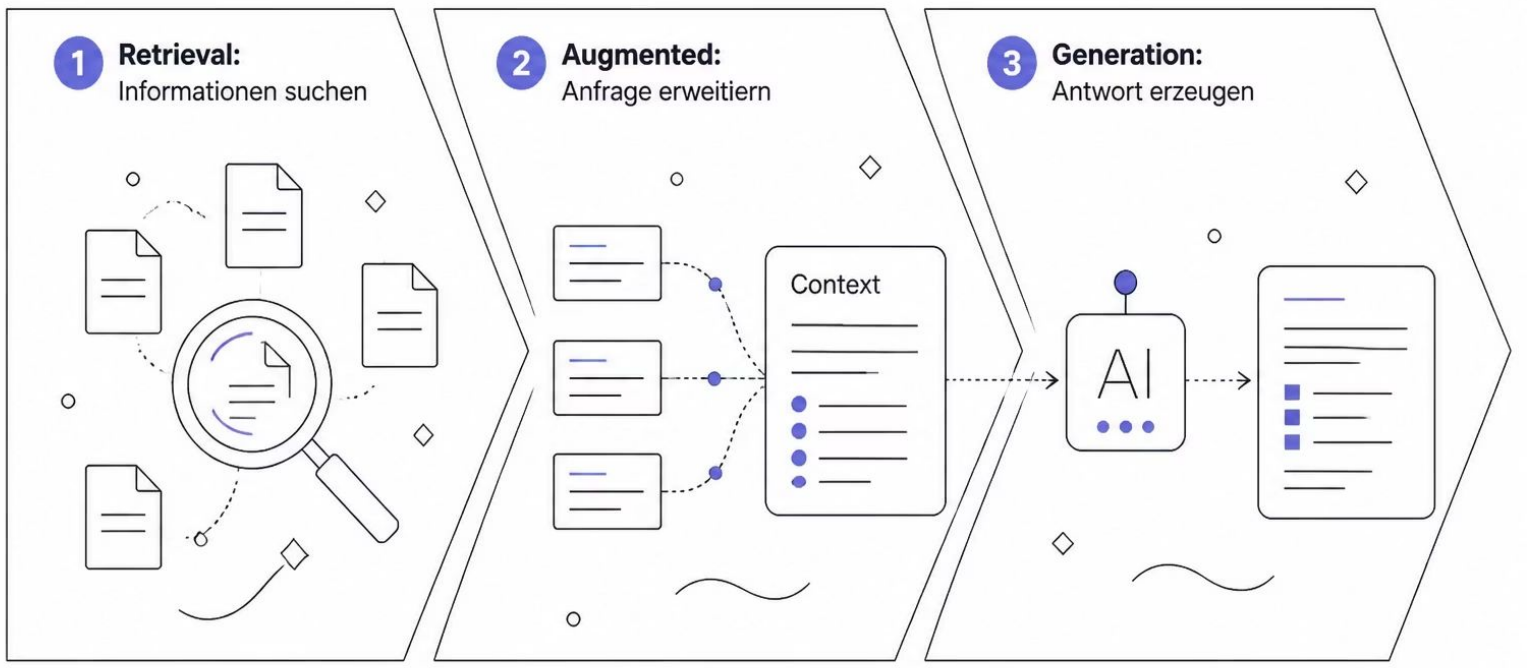



# Was passiert bei:

- **10 Dokumenten?** Vielleicht noch machbar.
- **100 Dokumenten?** Zeitaufwendig und fehleranfällig.
- **10.000 Dokumenten?** Praktisch unmöglich und nicht skalierbar.

# RAG bedeutet: erst suchen, dann antworten

Retrieval-Augmented Generation (RAG) ermöglicht Sprachmodellen, präzisere und relevantere Antworten zu liefern, indem es sie mit externen Informationsquellen verbindet. Es funktioniert in drei Hauptphasen:




1

### Retrieval: Informationen suchen

Die KI durchsucht eine Wissensdatenbank (z.B. Ihre internen Dokumente) nach relevanten Informationen, die zur Anfrage des Nutzers passen.

2

### Augmented: Anfrage erweitern

Die gefundenen Informationen werden als zusätzlicher Kontext zur ursprünglichen Anfrage hinzugefügt, wodurch die KI eine fundiertere Grundlage erhält.

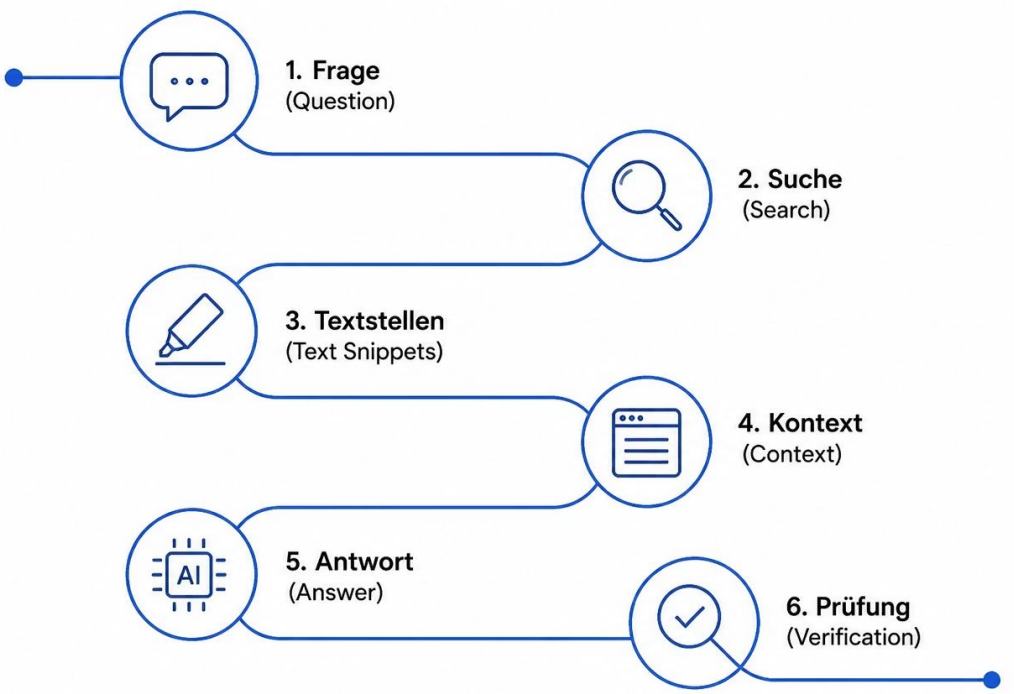
3

### Generation: Antwort erzeugen

Das Sprachmodell generiert eine präzise und umfassende Antwort, die sowohl auf seinem allgemeinen Wissen als auch auf den bereitgestellten spezifischen Informationen basiert.

# Eine RAG-Anfrage durchläuft mehrere Schritte

Um präzise und fundierte Antworten zu liefern, folgt eine RAG-Anfrage einem strukturierten Prozess, der von der initialen Frage bis zur verifizierten Antwort führt.




***Dieser Ablauf stellt sicher, dass die generierte Antwort nicht nur relevant ist, sondern auch auf überprüfbaren und aktuellen Informationen basiert.***

# Dokumente werden in Chunks zerlegt

Um große Informationsmengen effizient für Retrieval-Augmented Generation (RAG) nutzen zu können, werden umfassende Dokumente wie Produktkataloge, Handbücher oder interne Richtlinien in kleinere, verwaltbare Einheiten, sogenannte "Chunks", aufgeteilt.

Ein Produktkatalog könnte beispielsweise in folgende Abschnitte zerlegt werden:

- Funktionen
- Preise
- Rabatte
- Vertragsbedingungen
- FAQ

Diese Strukturierung ermöglicht eine präzisere und relevantere Informationssuche.



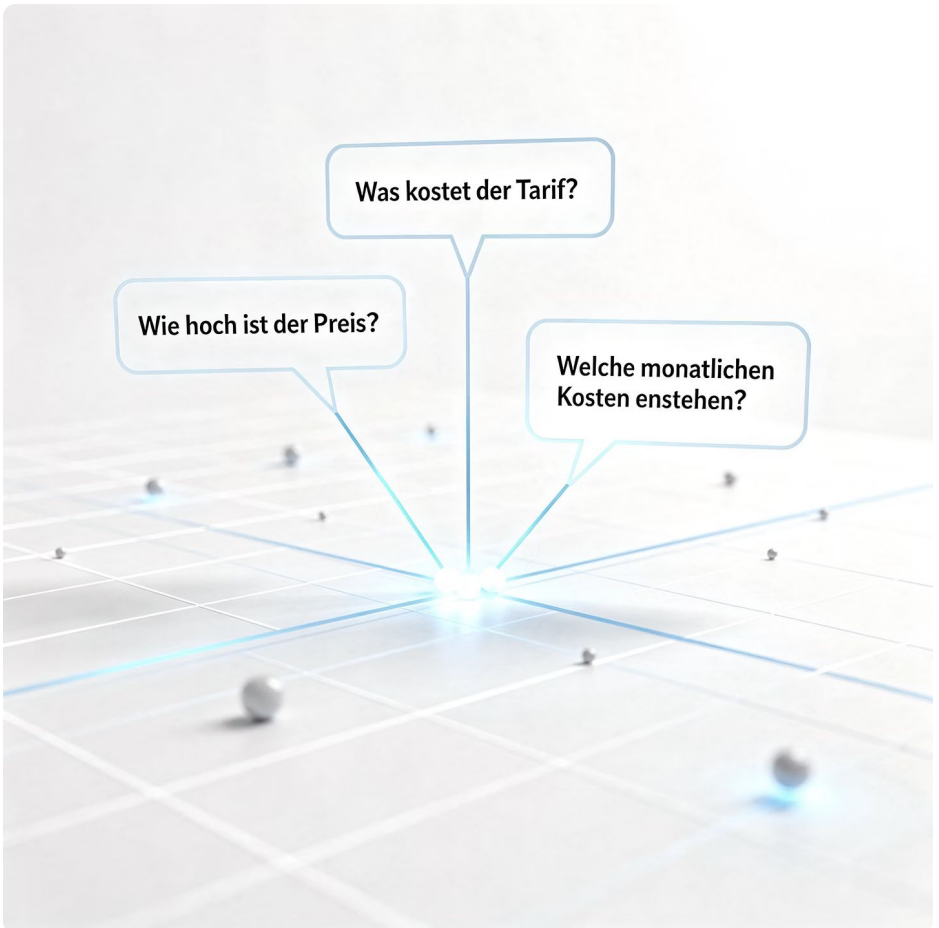
# Embeddings bilden Bedeutung mathematisch ab

Sprachmodelle übersetzen Wörter und Phrasen in sogenannte "Embeddings" – numerische Vektoren, die ihre Bedeutung in einem hochdimensionalen Raum darstellen.

Phrasen, die eine ähnliche Bedeutung tragen, werden in diesem semantischen Raum nah beieinander platziert, auch wenn sie unterschiedlich formuliert sind:

> „Was kostet der Tarif?"
>
> „Wie hoch ist der Preis?"
>
> „Welche monatlichen Kosten entstehen?"

Diese mathematische Repräsentation ermöglicht es der KI, die semantische Nähe zwischen Ihrer Anfrage und den Informationen in den Dokumenten zu erkennen.



# Semantische Suche und Kontextfenster

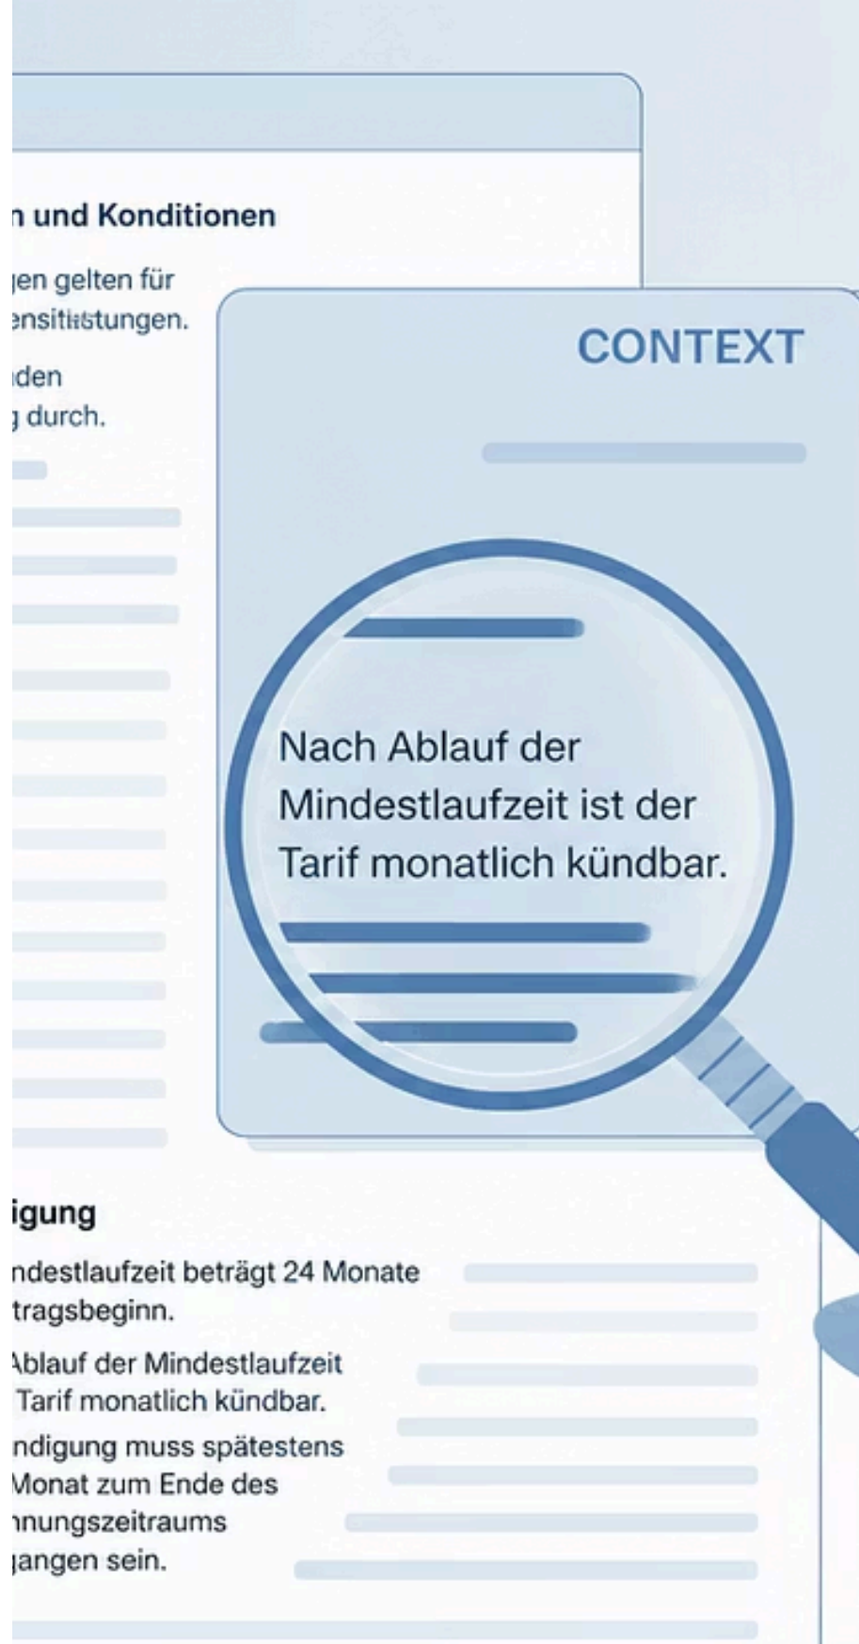
RAG-Systeme nutzen eine ausgeklügelte semantische Suche, um die relevantesten Informationen für Ihre Anfrage zu finden. Dabei werden nicht nur Stichwörter abgeglichen, sondern die tatsächliche Bedeutung der Inhalte.

- RAG sucht nach inhaltlich passenden Textabschnitten, nicht nur nach Keywords.
- Nur die semantisch relevantesten Chunks gelangen ins Kontextfenster des Sprachmodells.
- Das Kontextfenster ist begrenzt – Effizienz ist hier entscheidend.
- Mehr Kontext ist nicht automatisch besser; Präzision ist der Schlüssel.

### Beispiel:

> *Nutzerfrage:* „Kann ich den Vertrag jeden Monat beenden?“
>
> *Passender Dokumentabschnitt:* „Nach Ablauf der Mindestlaufzeit ist der Tarif monatlich kündbar.“

Durch die semantische Analyse wird der passende Abschnitt gefunden, auch wenn die Formulierungen variieren.



# Die Wissensbasis entscheidet über die Qualität

Die Leistungsfähigkeit eines RAG-Systems ist direkt an die Qualität der zugrunde liegenden Wissensbasis gekoppelt. Nur mit verlässlichen und relevanten Daten kann die KI präzise und vertrauenswürdige Antworten liefern.

## Optimale Wissensbasis




- Aktuell: Informationen sind auf dem neuesten Stand.
- Eindeutig: Keine widersprüchlichen Angaben.
- Strukturiert: Leichte Auffindbarkeit von Inhalten.
- Freigegeben: Offiziell geprüfte und genehmigte Inhalte.
- Versioniert: Nachvollziehbare Änderungen.

## Typische Probleme



- Alte Preislisten: Veraltete Konditionen.
- Widersprüchliche Bedingungen: Uneinheitliche Aussagen.
- Unklare Dokumenttitel: Erschwerte Identifizierung.
- Ungeprüfte Notizen: Fehleranfällige Inhalte.
- Fehlende Informationen: Lückenhaftes Wissen.

> **Kernaussage:** RAG kann schlechte oder widersprüchliche Unternehmensinformationen nicht automatisch korrigieren. Die Qualität der Ergebnisse hängt maßgeblich von der Datenpflege ab.

# Vertriebsbeispiel: Mehrere Quellen ergeben eine Antwort

### Kundenfrage:

„Was kosten zwölf Professional-Lizenzen und können wir monatlich kündigen?“

### Benötigte Quellen:

- Aktuelle Preisliste
- Rabattregeln
- Vertragsbedingungen

---

### Berechnung:

`12 × 89€ = 1.068€`

`1.068€ - 15% = 907,80€`

---

### Zusatzinformation:

Zwölf Monate Mindestlaufzeit, danach monatlich kündbar.

# Spiel: Die menschliche RAG-Pipeline

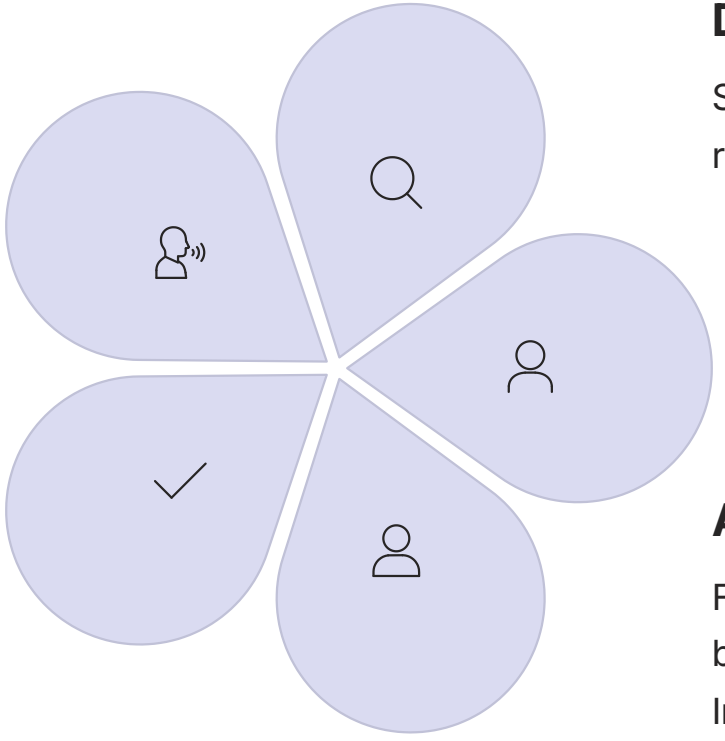
Um den RAG-Prozess besser zu verstehen, stellen wir uns ein Team von fünf Personen vor, das gemeinsam eine Anfrage bearbeitet – wie eine menschliche RAG-Pipeline:

### Fragesteller

Definiert die ursprüngliche Frage und die Informationsbedürfnisse.

### Prüfer

Überprüft die Endantwort auf Richtigkeit, Vollständigkeit und Verständlichkeit.



### Dokumenten-Rechercheur

Sucht in der Wissensbasis nach relevanten Dokumentenabschnitten.

### Wissensmanager

Prüft die Relevanz und Genauigkeit der gefundenen Informationen.

### Antwortgeber

Formuliert eine kohärente Antwort basierend auf den bereitgestellten Informationen.

Jede dieser Rollen beeinflusst maßgeblich die Qualität und Zuverlässigkeit der abschließenden Antwort. Ein Fehltritt in einer Phase kann die gesamte Ausgabe beeinträchtigen.

# Eure Aufgabe: Von der Frage zur belegten Antwort

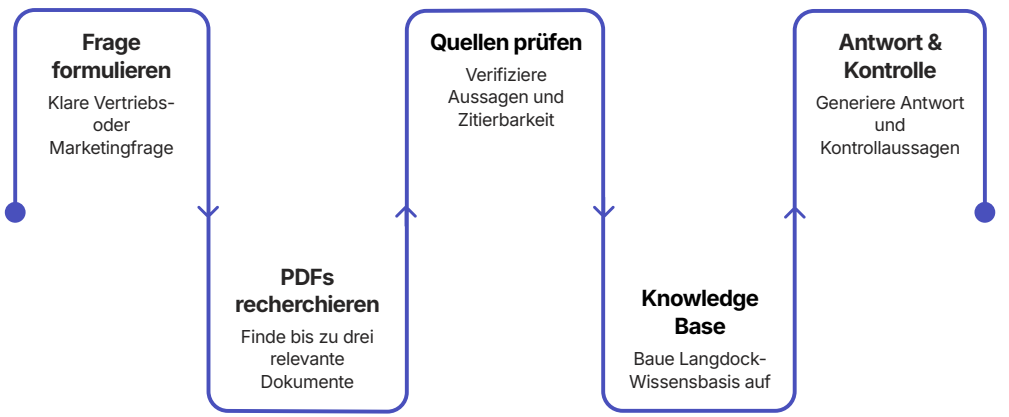
## Inhalt:

Entwickelt eine Frage aus Vertrieb oder Marketing. Findet maximal drei geeignete PDF-Dokumente und beantwortet die Frage ausschließlich anhand dieser Quellen.

## Regel:

**Was nicht belegt ist, darf nicht als Tatsache dargestellt werden.**

## Ablauf:




Dieser Prozess bildet die menschliche RAG-Pipeline nach, bei der jede Phase kritisch für die Qualität der Endantwort ist.

# Quellen und Antworten systematisch prüfen

## Vor dem Upload

- Wer ist der Herausgeber?
- Wie aktuell ist das Dokument?
- Handelt es sich um eine Studie oder Werbung?
- Passt die Quelle zur Frage?

## Nach der Antwort

- Ist jede Aussage belegt?
- Wurden Zahlen korrekt übernommen?
- Fehlen wichtige Informationen?
- Widersprechen sich die Quellen?

## Bewertung

BELEGT | NICHT BELEGT | WIDERSPRÜCHLICH | FALSCH | VERALTET

# RAG unterstützt Vertrieb und Marketing




## Vertrieb

- Produktfragen beantworten
- Verkaufsgespräche vorbereiten
- Angebote unterstützen
- Einwände bearbeiten

## Marketing

- Produkttexte erstellen
- Studien auswerten
- Markenrichtlinien anwenden
- Fallstudien nutzen

> **Kernaussage:** RAG macht vorhandenes Wissen schneller auffindbar und nutzbar.

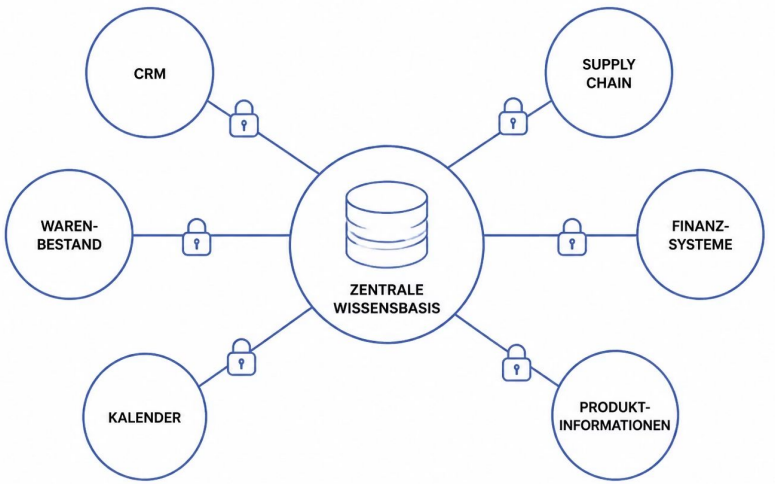
# RAG hat klare Grenzen

## Nicht geeignet für:

- Live-Lagerbestände
- Aktuellen CRM-Status
- Offene Rechnungen
- Verfügbare Termine
- Rechtliche Freigaben

## Zu beachten:

- Datenschutz
- Zugriffsrechte
- Dokumentenpflege
- Menschliche Kontrolle



# RAG Rescue: Rettet die Kundenantwort

Im interaktiven Spiel durchlaufen wir die RAG-Pipeline von der Anfrage bis zur verifizierten Antwort:

01

## Kundenfrage analysieren

Verstehen Sie das Kernanliegen des Kunden.

02

## Dokumente auswählen

Wählen Sie relevante interne Quellen aus der Wissensbasis.

03

## Chunks in den Kontext legen

Extrahieren Sie die wichtigsten Textabschnitte für die KI.

04

## KI-Antwort erzeugen

Lassen Sie die KI eine erste Entwurfsantwort generieren.

05

## Fehler und Halluzinationen finden

Überprüfen Sie die KI-Antwort kritisch auf Ungenauigkeiten.

06

## Antwort reparieren

Korrigieren Sie die Antwort, um sie korrekt und umfassend zu machen.

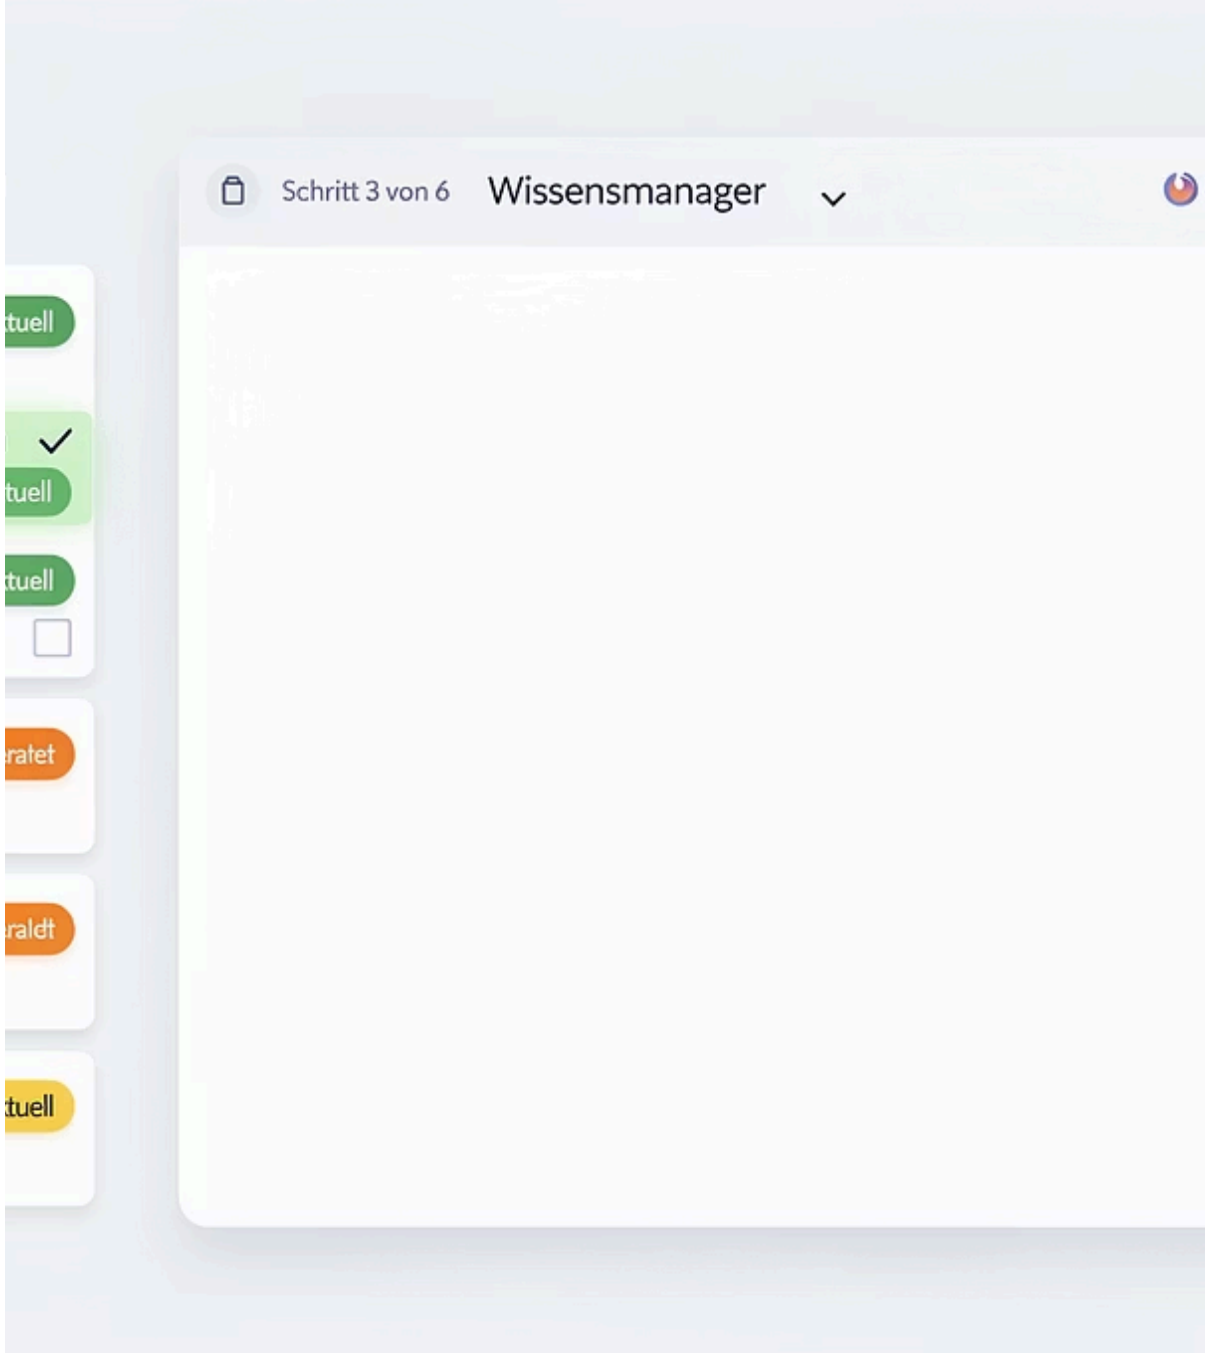
RAG RESCUE SCHRITT 3 VON 6 WISSENSMANAGER

# RAG Rescue: Rettet die Kundenantwort

Wählt die richtigen Quellen, baut den Kontext auf und findet die Fehler der KI.

> Die Gruppe entscheidet selbst, welche Informationen die KI für ihre Antwort erhält.

Frage → Dokumente → Chunks → Kontext → KI-Antwort → Prüfung



# Eine gute RAG-Antwort entsteht als Prozess

Eine zuverlässige Antwort basiert auf einem mehrstufigen und sorgfältigen Vorgehen:

- Eine klare Frage
- Geeignete Quellen
- Relevante Textausschnitte (Chunks)
- Ein passender Kontext
- Klare Anweisungen an die KI
- Eine abschließende menschliche Prüfung

## Abschlussfrage:

Wo könnte RAG in Ihrem Arbeitsalltag helfen – und welche Dokumente wären dafür notwendig?