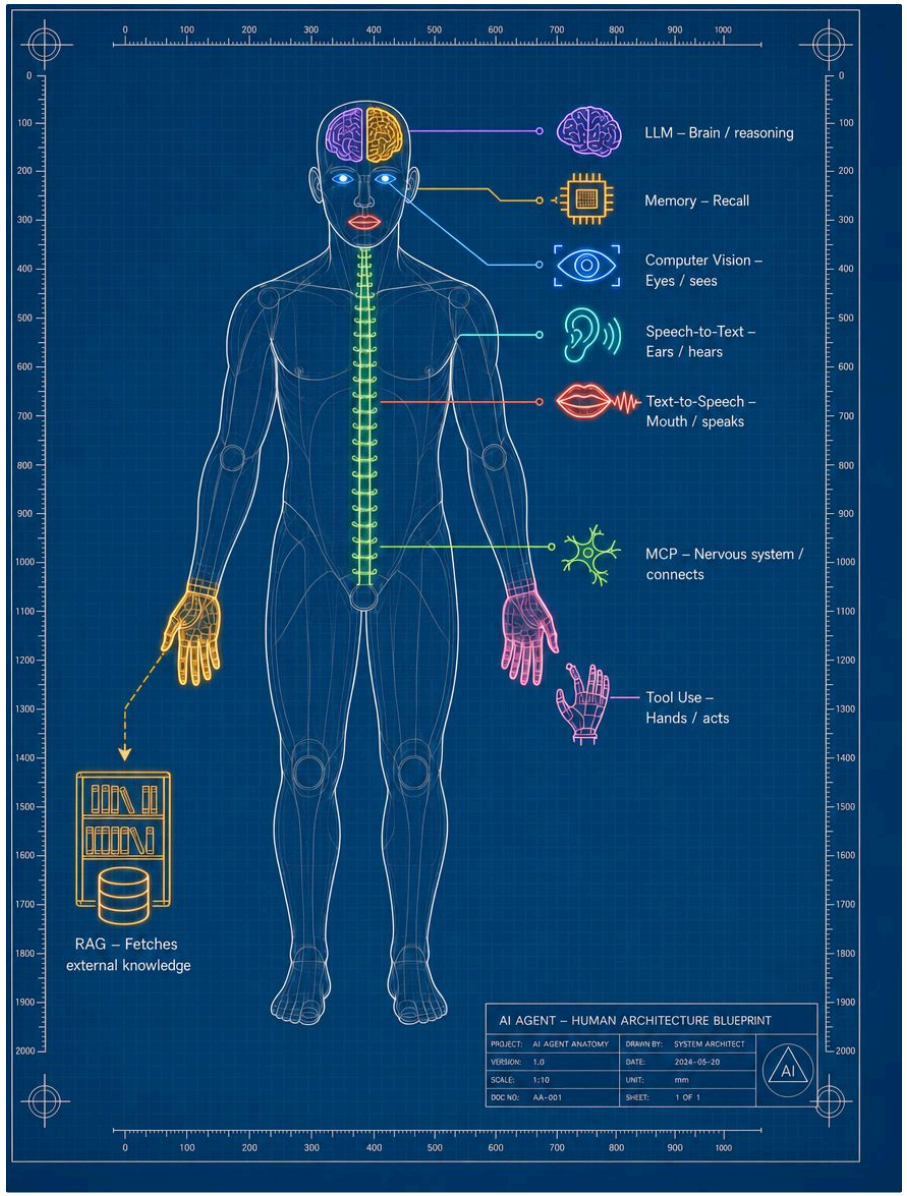
FUTUREWAY
KI INSTITUT

# Modul 1: KI-Grundlagen

## Lektion 8: Agenten

KI Automations Spezialist

Juli 2026


LLM – Brain / reasoning
Memory – Recall
Computer Vision – Eyes / sees
Speech-to-Text – Ears / hears
Text-to-Speech – Mouth / speaks
MCP – Nervous system / connects
Tool Use – Hands / acts
RAG – Fetches external knowledge
AI AGENT – HUMAN ARCHITECTURE BLUEPRINT
PROJECT: AI AGENT ANATOMY
DRAWN BY: SYSTEM ARCHITECT
VERSION: 1.0
DATE: 2024-05-20
SCALE: 1:10
UNIT: mm
DOC NO: AA-001
SHEET: 1 OF 1
AI

# Generative vs. Agentische KI

Das Verständnis des grundlegenden Unterschieds zwischen generativer und agentischer Künstlicher Intelligenz ist entscheidend, um ihre jeweiligen Stärken und Anwendungsbereiche zu erkennen.

## Generative KI

**Reaktiv:** Erzeugt auf einen gegebenen Prompt hin Inhalte wie Texte, Bilder, Musik oder Code. Ihre Stärke liegt im Kreieren und Erstellen von Neuem, basierend auf Mustern, die sie aus riesigen Datenmengen gelernt hat. Sie agiert nicht proaktiv und trifft keine eigenständigen Entscheidungen zur Zielerreichung.

## Agentische KI

**Proaktiv:** Trifft Entscheidungen, plant Schritte und handelt selbstständig, um ein vorgegebenes Ziel mit minimaler menschlicher Aufsicht zu erreichen. Sie ist darauf ausgelegt, Aufgaben auszuführen, sich an veränderte Bedingungen anzupassen und ergebnisorientiert zu agieren.

> **Merksatz:** Generative KI erstellt Inhalte, agentische KI trifft Entscheidungen und führt aus.

# Was ist ein Agent?



## Autonome Aufgabenausführung

Ein KI-Agent ist ein System, das autonom Aufgaben ausführt, indem es seinen Workflow selbst gestaltet und verfügbare Tools nutzt.



## LLM als „Gehirn"

Im Kern arbeitet ein LLM als zentrales Steuerungselement — deshalb wird oft auch von einem LLM-Agenten gesprochen.



## Mehr als ein reines LLM

Tool-Aufrufe holen aktuelle Informationen, erzeugen Teilaufgaben und erreichen komplexe Ziele — teils ohne menschliches Eingreifen.

# Komponenten eines KI-Agenten

Ein effektiver KI-Agent integriert mehrere Kernfunktionen, die ihm ermöglichen, autonom und zielgerichtet zu handeln.

## Wahrnehmung

Nimmt Eingaben aus der Umgebung auf und interpretiert diese mittels NLP, Bilderkennung oder Sensor-/API-Daten.

## Gedächtnis

Verfügt über ein Kurzzeitgedächtnis (Sitzung) und ein Langzeitgedächtnis (Wissensdatenbank, Vektor-Embeddings).

## Planung

Zerlegt komplexe Probleme in handhabbare Teilaufgaben und bestimmt deren Abhängigkeiten für eine strategische Ausführung.

## Argumentation/Entscheidung

Wägt mögliche Lösungswege ab, basierend auf regelbasierter Logik, probabilistischen Modellen oder Chain-of-Thought-Ansätzen.

## Action & Tool Calling

Führt Entscheidungen aus, indem es APIs aufruft, Systeme bedient und externe Tools effektiv nutzt.

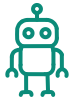
## Kommunikation

Interagiert nahtlos mit menschlichen Nutzern und anderen KI-Agenten, um Informationen auszutauschen und Koordination zu ermöglichen.

## Lernen & Anpassung

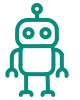
Verbessert seine Leistung kontinuierlich durch die Analyse von Erfahrungen und die Anpassung seiner Strategien.

# Kernmerkmale eines KI-Agenten



## Autonom

Verfolgt langfristige Ziele, bewältigt mehrstufige Aufgaben und überwacht den Fortschritt ohne ständige menschliche Aufsicht.



## Proaktiv

Verbindet die Flexibilität von LLMs mit der Zuverlässigkeit klassischer Programmierung; sucht im Web, ruft APIs auf, fragt Datenbanken ab und erfasst Echtzeitdaten.



## Spezialisiert

Reicht von simplen wiederkehrenden Aufgaben bis zu komplexen Problemlösungen. Architekturen variieren vom „Dirigenten"-Modell bis zur dezentralen Zusammenarbeit.



## Anpassungsfähig

Lernt aus Erfahrung, integriert Feedback und verbessert sich kontinuierlich. Multiagentensysteme skalieren für breite Initiativen.



## Intuitiv

Steuerung per natürlicher Sprache. Ganze Software-Oberflächen lassen sich auf ein „Gespräch" mit dem Agenten reduzieren.

# KI-Assistent vs. KI-Agent

Das Verständnis der spezifischen Merkmale von KI-Assistenten und KI-Agenten ist entscheidend, um ihre optimalen Einsatzbereiche zu identifizieren.

| Merkmal | KI-Assistent | KI-Agent |
|---|---|---|
| **Auslöser** | Benötigt bei jeder Aktion einen **Prompt** | Ein **Prompt genügt**, agiert dann **eigenständig** |
| **Autonomie** | Schlägt vor, **Nutzer entscheidet** | **Entscheidet & handelt** selbst |
| **Tools** | **Vordefinierte** Funktionen | **Wählt Tools** selbst |
| **Gedächtnis** | Meist **kein persistenter** Speicher | **Dauerhaftes** Gedächtnis, lernt dazu |
| **Aufgaben** | **Einzeln**, dialoggeführt | **Verkettet**, in Teilaufgaben zerlegt |
| **Zuverlässigkeit** | **Hoch** (keine externen Tools) | Abhängig von Tools/APIs, **fehleranfälliger** |

KI-Assistenten sind ideal für klar umrissene, benutzergeführte Aufgaben, während KI-Agenten für mehrstufige Ziele mit Eigeninitiative und Tool-Orchestrierung konzipiert sind.

# Technischer Rahmen eines KI-Agenten

Der technische Rahmen, oft als "Agent Harness" bezeichnet, bildet die Infrastruktur, die es einem KI-Agenten ermöglicht, seine Aufgaben zu erfüllen und mit der Umgebung zu interagieren.



## LLM (Sprach-/Reasoning-Modell)

Das Herzstück des Agenten, das für Sprachverständnis, Entscheidungsfindung und logisches Denken verantwortlich ist.



## Tools/Aktionen

Eine Sammlung von externen Funktionen und APIs (z.B. Websuche, Datenanalyse, Integrationen), die der Agent zur Ausführung von Aufgaben nutzen kann.



## Code / Laufzeitumgebung

Die Umgebung, in der der Agent seinen selbstgenerierten Code ausführt und die notwendigen Schritte zur Problemlösung umsetzt.



## Wissen

Externe Wissensquellen wie angehängte Dokumente, Ordnerstrukturen oder Vektordatenbanken, die der Agent für Kontext und Fakten abfragen kann.



## Steuerung

Definierte System-Prompts, Regeln und Abbruchbedingungen, die das Verhalten des Agenten leiten und unerwünschte Aktionen verhindern.

# Prompting von Agents

Die Art, wie ein Agent mit Prompts gesteuert wird, bestimmt maßgeblich, wie er denkt, plant und handelt – zwei grundlegende Strategien unterscheiden sich dabei in Struktur und Effizienz.

## ReAct (Reasoning + Acting)

**Denken → Handeln → Beobachten** in einer kontinuierlichen Schleife. Nach jedem Tool-Ergebnis wird der Plan neu bewertet und der nächste Schritt dynamisch festgelegt.

- Reagiert flexibel auf neue Informationen
- Jeder Zwischenschritt ist transparent nachvollziehbar
- **Vorteile:** Transparent, flexibel, adaptiv

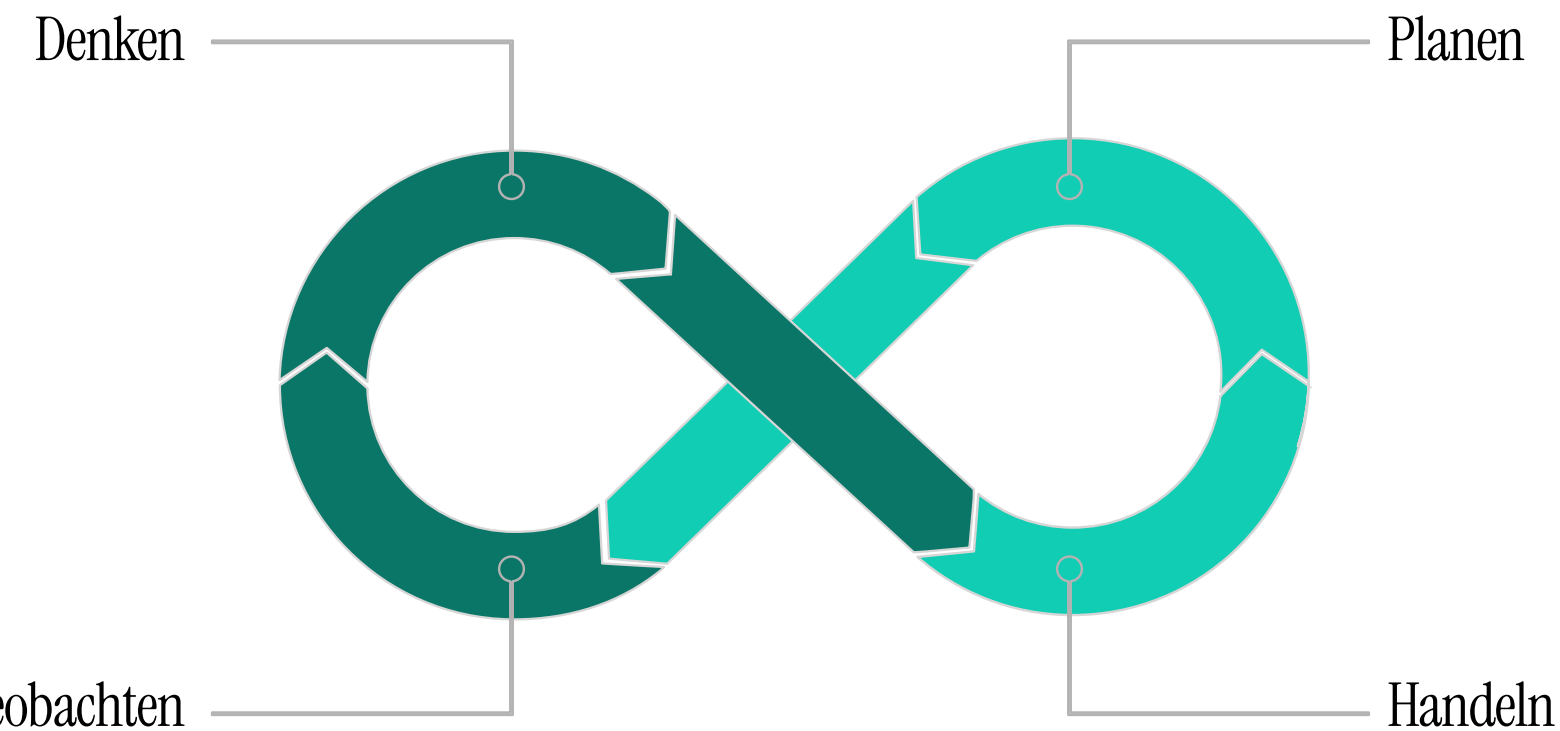
## ReWOO (Reasoning WithOut Observation)

**Vorabplanung aller Schritte** – der Agent erstellt zunächst einen vollständigen Plan und ruft alle benötigten Tools gebündelt auf, ohne auf Zwischenergebnisse zu warten.

- Spart Tokens und reduziert Rechenzeit erheblich
- Nutzer kann den Plan vor der Ausführung prüfen und bestätigen
- **Vorteile:** Effizient, vorhersehbar, kontrollierbar

# Looping

Der KI-Agent agiert nicht nach einem festen Skript, sondern iteriert selbstständig, bis er sein definiertes Ziel erreicht hat.




Das Herzstück des agentischen Verhaltens: Der Agent entscheidet nach jedem Handlungs- und Beobachtungsschritt autonom, ob er sein Ziel erreicht hat oder weitere Schritte erforderlich sind.

## Dynamische Iteration

Die Anzahl der Schleifendurchläufe ist nicht vordefiniert, sondern wird vom Agenten zur Laufzeit flexibel bestimmt.

## Steuerung durch Abbruchbedingungen

Der Agent beendet die Schleife bei:

- Zielerreichung
- Maximaler Schritt-/Iterartionszahl
- Zeit- oder Token-Budget-Überschreitung
- Menschlichem Eingriff (Human-in-the-Loop)

## Risikomanagement

**Ohne saubere Abbruchbedingungen drohen Endlosschleifen** – dies führt zu unnötigen Kosten und Latenzen. Monitoring und Unterbrechbarkeit sind daher essenziell.



# Human-in-the-Loop

Der "Human-in-the-Loop"-Ansatz integriert menschliche Aufsicht und Intervention in die Abläufe von KI-Agenten, um Sicherheit, Qualität und Lernprozesse zu gewährleisten.

## Menschliche Freigabe

Vor kritischen Aktionen (z.B. Massen-E-Mails, Finanztransaktionen) holt der Agent eine menschliche Bestätigung ein.

## Workflow pausieren

Der Agent unterbricht seinen Workflow, bis ein Mensch die Fortsetzung der Aufgabe bestätigt oder korrigiert.

## Feedback ins Lernen

Menschliches Feedback und Korrekturen fliessen direkt in das Lernmodell des Agenten zurück und verbessern seine zukünftige Leistung.

## Notfall-Deaktivierung

In Hochrisiko-Umgebungen kann der Agent bei Fehlverhalten oder unerwarteten Situationen sofort deaktiviert werden.

# Evaluierung & Observability

Um die Zuverlässigkeit und Effektivität von KI-Agenten zu gewährleisten, sind sowohl eine präzise Evaluierung der Ergebnisse als auch eine transparente Beobachtbarkeit ihrer internen Prozesse unerlässlich.

## Evaluierung: Stimmt die Antwort?

Die Messung der Qualität der Agenten-Outputs ist entscheidend. Hierbei fokussieren wir uns auf folgende Metriken:

- **Kontextrelevanz:** Wie gut passt die Antwort zum gegebenen Kontext?
- **Treue:** Entsprechen die Fakten in der Antwort den zugrundeliegenden Informationen?
- **Antwortähnlichkeit:** Wie konsistent sind die Antworten bei wiederholten Anfragen?

## Observability/Tracing/Analytics: Was hat der Agent getan?

Ein tiefer Einblick in die Arbeitsweise des Agenten ermöglicht die Diagnose und Optimierung. Dies geschieht durch:

- **Logs:** Detaillierte Protokolle der einzelnen Schritte und Entscheidungen des Agenten.
- **Traces:** Nachverfolgung des gesamten Ausführungspfads einer Aufgabe, einschliesslich Tool-Nutzung und Interaktionen.
- **Usage Insights:** Aktivitätsmetriken, Nutzerzahlen und Trends geben Aufschluss über die tatsächliche Nutzung des Agenten.
- **Feedback:** Auswertung von Nutzer-Feedback (z.B. Daumen hoch/runter) zur kontinuierlichen Qualitätsverbesserung.

Aktivitätsprotokolle und Traces schaffen Transparenz und Vertrauen in die Agentenleistung, wodurch Fehler schnell identifiziert und behoben werden können.

**Governance-Agenten:** Eine innovative Idee sind spezielle KI-Agenten, die darauf trainiert sind, andere Agenten zu überwachen, deren Leistung zu bewerten und bei Bedarf einzugreifen oder Optimierungsvorschläge zu unterbreiten.

# Governance, Risiken & Sicherheit

Die Autonomie von KI-Agenten birgt spezifische Herausforderungen in Bezug auf Kontrolle, Ethik und Sicherheit, die durch geeignete Massnahmen gemindert werden müssen.

## Risiken durch Autonomie & Komplexität

- **Black Box:** Entscheidungen sind oft nicht nachvollziehbar, was die Kontrolle erschwert.
- **Bias:** Agenten können bestehende Verzerrungen in Trainingsdaten verstärken.
- **Sicherheitslücken:** Schwach kontrollierte APIs bieten Angriffsflächen für Datenlecks oder adversariale Attacken.

## Massnahmen zur Kontrolle & Absicherung

- **Zugriffs-/Authentifizierungskontrollen:** Schutz kritischer Schnittstellen.
- **Verschlüsselung:** Sicherung sensibler Daten und Kommunikation.
- **Eindeutige Agenten-IDs:** Für vollständige Rückverfolgbarkeit von Aktionen.
- **Menschliche Aufsicht:** Human-in-the-Loop-Mechanismen für kritische Entscheidungen.

⚠ Die bestehende Regulierung (z.B. EU AI Act) hinkt der rasanten technischen Entwicklung oft noch hinterher, was zusätzliche Eigenverantwortung erfordert.

# Multi-Agenten-Systeme

# Sub-Agents: Aufgaben delegieren

Multi-Agenten-Systeme ermöglichen es, komplexe Herausforderungen durch die Aufteilung in spezialisierte Teilaufgaben effizienter zu lösen.

## Delegation durch Eltern-Agent

Ein übergeordneter "Eltern-Agent" hängt spezialisierte Sub-Agents an und delegiert ihnen gezielte Teilaufgaben.

## Autonomie der Sub-Agents

Jeder Sub-Agent arbeitet eigenständig mit eigenen Instruktionen, einer spezifischen Wissensbasis, Tools und einem optimierten Modell.

## Fokus & Effizienz

Statt einen Agenten zu überladen, entstehen fokussierte Spezialisten, die Aufgaben präzise und effizient bearbeiten.



# Wer koordiniert die Agenten?

Die Art und Weise, wie KI-Agenten in einem Multi-Agenten-System zusammenarbeiten, hängt von der gewählten Koordinationsstrategie ab. Jede Strategie hat spezifische Vor- und Nachteile.



## Zentralisiert

Ein Orchestrator fungiert als zentrales "Gehirn", das Aufgaben verteilt, die Ausführung überwacht und finale Entscheidungen trifft. Dies ermöglicht eine hohe Kontrolle und Koordination, kann aber einen Engpass darstellen.



## Dezentralisiert

Agenten stimmen sich direkt miteinander ab, ohne eine zentrale Instanz. Dies fördert Skalierbarkeit und Ausfallsicherheit, erfordert jedoch robuste Kommunikations- und Konsensmechanismen.



## Hierarchisch

Agenten sind in Ebenen organisiert, ähnlich einer Unternehmensstruktur. Manager-Agenten steuern Ausführungs-Agenten, delegieren Aufgaben und berichten an höhere Ebenen. Ideal für komplexe, strukturierte Projekte.



## Föderiert

Agenten arbeiten über Organisationsgrenzen hinweg zusammen, ohne alle Daten zu teilen. Dies ist besonders relevant für datenschutzsensible Anwendungsfälle, bei denen nur aggregierte oder anonymisierte Informationen ausgetauscht werden.

# Warum überhaupt mehrere Agenten?

Einzelsysteme stoßen bei der Bewältigung komplexer, mehrstufiger Herausforderungen schnell an ihre Grenzen. Multi-Agenten-Systeme bieten hier leistungsstarke Lösungsansätze, bergen aber auch spezifische Herausforderungen in der Koordination.

## Vorteile

- **Höhere Leistung:** Spezialisierte Agenten können Teilprobleme parallel und effizienter bearbeiten.
- **Fehlertoleranz:** Der Ausfall eines Agenten muss nicht das gesamte System lahmlegen, andere können Aufgaben übernehmen.
- **Skalierbarkeit:** Neue Agenten können bei Bedarf hinzugefügt werden, um größere Arbeitslasten zu bewältigen.
- **Selbst-optimierende Workflows:** Durch die Interaktion und Anpassung der Agenten können sich Prozesse kontinuierlich verbessern.

## Risiken

- **Gemeinsame Schwachstellen:** Bei Nutzung des gleichen Basismodells (LLM) können sich Fehler oder Halluzinationen multiplizieren.
- **Koordinationsfehler:** Fehlkommunikation oder widersprüchliche Ziele zwischen Agenten können zu suboptimalen Ergebnissen führen.
- **Endlosschleifen:** Agenten können in Schleifen gefangen sein, wenn sie sich gegenseitig mit unklaren Anweisungen füttern oder keine Abbruchbedingung erreicht wird.

# Wie wird ein Agent gestartet?

KI-Agenten können auf verschiedene Weisen aktiviert werden, je nach ihrer Aufgabe und der gewünschten Interaktion. Diese Trigger definieren, wann und wie ein Agent seine Arbeit aufnimmt.



## Chat

Startet durch direkte Text- oder Sprachinteraktion in einer Konversation mit dem Benutzer.



## Formular

Beginnt die Arbeit, sobald strukturierte Eingaben über ein digitales Formular gesammelt und übermittelt wurden.



## Geplant

Wird zu vordefinierten Zeiten oder Intervallen aktiviert, ideal für regelmäßige Berichte oder Routineaufgaben.



## Webhook / API

Reagiert auf eingehende Anfragen oder Daten von externen Systemen über definierte Schnittstellen.



## Integration

Löst eine Aktion aus, wenn ein bestimmtes Ereignis in einer verbundenen Anwendung auftritt (z.B. neue E-Mail, aktualisiertes Ticket).



## Manuell

Wird direkt durch eine Benutzeraktion gestartet, z.B. per Knopfdruck für Ad-hoc-Analysen oder Tests.

# Deployment & Tool-Landschaft

Die effektive Implementierung von KI-Agenten erfordert eine sorgfältig ausgewählte Tool-Landschaft und robuste Deployment-Strategien, um ihre Leistungsfähigkeit voll auszuschöpfen und die Integration in bestehende Systeme zu gewährleisten.



## Langdock

Eine umfassende Plattform für die Entwicklung und Bereitstellung von Chatbots, Agenten, Workflows und Integrationen.



## n8n

Ein flexibles Open-Source-Tool für visuelle Workflow-Automatisierung und Orchestrierung komplexer Agenten-Aufgaben.



## Claude Agenten-Suiten

Spezialisierte agentische Arbeits- und Coding-Umgebungen von Anthropic (z.B. Cowork, Code, Managed Agents).



## Hermes, OpenClaw, ...

Wichtige Bausteine und Frameworks, die das Ökosystem für Agenten-Entwicklung und -Interoperabilität erweitern.

## Protokolle für die Agenten-Vernetzung

- **MCP (Message Communication Protocol):** Standardisiert die Anbindung und Interaktion von Tools mit Agenten.
- **A2A (Agent-to-Agent Communication):** Ermöglicht die direkte und effiziente Kommunikation zwischen verschiedenen KI-Agenten.