FUTUREWAY
KI INSTITUT

Modul 1: KI-Grundlagen

Lektion 10: KI-Infrastruktur

KI Automations Spezialist

Juli 2026



Welcher Technologie-Stack ist der richtige?

- Was brauche ich technisch?
- Wie viel baue ich selbst?

Warum eigene Infrastruktur?

Datensouveränität

Daten auf eigenen Servern.

Compliance

Kontrolle über Infrastruktur = Kontrolle über Compliance.

Kein Lock-in

Volle Portabilität, keine Abhängigkeit von US-Anbietern.

Planbare Kosten

Token/Infra statt variablem Per-Seat-Pricing.

⚠ **„Server in Frankfurt" ≠ souverän:** Der CLOUD Act gilt für US-Konzerne weltweit — unabhängig vom Serverstandort.

DSGVO

EU-Datenschutzgrundverordnung: Verarbeitung personenbezogener Daten

EU AI Act

Risikobasierte KI-Regulierung der EU, ab 2025 verbindlich

BSI C5

Bundesamt für Sicherheit: Cloud-Sicherheitsstandard für Deutschland

ISO 27001

Internationaler Standard für Informationssicherheits-Managementsysteme

SOC 2

US-Prüfstandard für Datensicherheit bei Dienstleistern

Serving-Engines

Einsatz auf Server (High-Performance-Anwendungen):

vLLM



vLLM



SGLang



NVIDIA



Ollama



llama.cpp



LM Studio



GPT4All



Hardware, VRAM & Quantisierung

VRAM ist der Engpass

FP16 braucht ~2 GB pro Mrd. Parameter:

- 7–8B → Laptop / Consumer-GPU
- 70B → Multi-GPU
- 100B+ → Cluster

Quantisierung: Gewichte von 16 → 8 → 4 Bit. Ein 70B-Modell schrumpft von ~140 GB auf ~40 GB — kaum Qualitätsverlust.

Die vier Standards

GGUF

Lokal, llama.cpp / Ollama

GPTQ

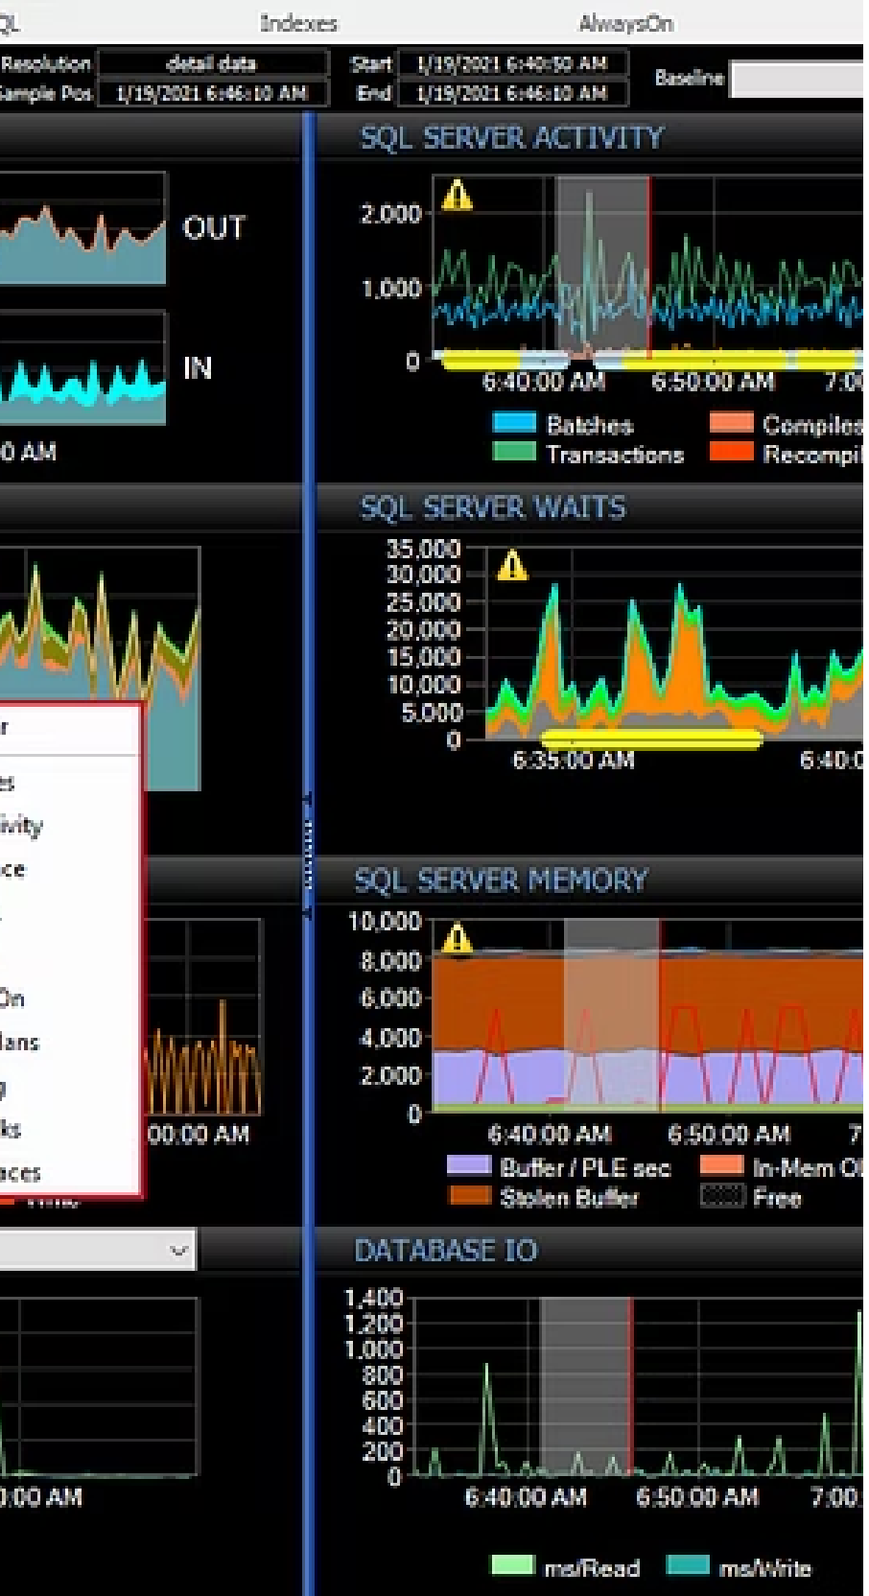
GPU, 4-Bit

AWQ

Qualitätsschonend, vLLM

FP8

Moderne GPUs, kaum Verlust



Betriebskennzahlen

TTFT

Time to First Token — gefühlte Reaktionszeit

Tokens/Sek. & Latenz

Wie flüssig streamt der Text; bestimmt Nutzererlebnis

Durchsatz & Concurrency

Parallele Nutzer → Kosten pro Nutzer

Trade-off

Niedrige Latenz ↔️ hoher Durchsatz — selten beides.

Die vier API-Typen

1

Completion

Text rein/raus. *„Die Hauptstadt von Bayern ist" → „München."* Heute Legacy.

2

Chat Completions

Nachrichten mit Rollen (system/user/assistant). De-facto-Standard mit Tool-Calling & Streaming.

3

Responses / Messages

Neue Generation (OpenAI Responses, Anthropic Messages): Tools, Zustand, Agenten.

4

Embeddings

Text → Vektor; Grundlage für Suche & RAG.

„OpenAI-kompatibel" ist die der Universal-Standard — Anbieterwechsel = nur `base_url` + Key tauschen. Das macht Souveränität praktisch machbar.

Aggregatoren

Aggregatoren bündeln mehrere API-Anbieter und ermöglichen so eine flexible Auswahl je nach Kosten, Verfügbarkeit und Spezialisierung der Modelle. Sie erleichtern die Integration und bieten oft zusätzliche Features wie Monitoring und automatisches Fallback.

OpenRouter

together.ai

Requesty

Fireworks AI

Azure AI Foundry

noirdoc.ai

INFERCOM

IONOS Momentum KI

STACKIT
A Brand of Schwarz Digits

AKI

Gateways

Key-Management, Budgets, Fallbacks, Logging, Limits









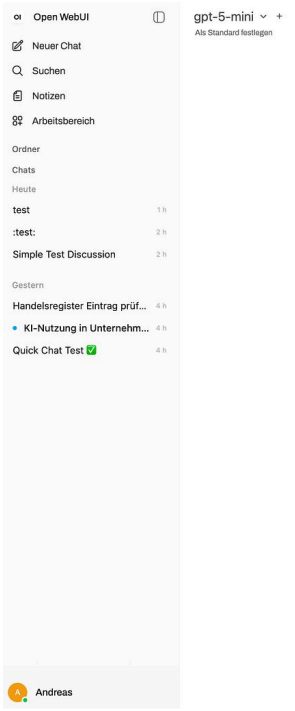
UI, RAG & Vektor-Datenbanken

Selbst-hostbare UIs (Open-Source)

- **Open WebUI** — beliebteste, RAG eingebaut
- **AnythingLLM** — Dokument-Fokus
- LibreChat · Jan

Vektor-DBs

- Qdrant (schnell) · Weaviate (Hybrid-Suche)
- Chroma (leichtgewichtig) · pgvector (in PostgreSQL)





KI-Plattformen











Die drei Betriebsmodelle

1

Turnkey

ChatGPT · Claude · Gemini · Copilot

Sofort einsatzbereit, beste Modelle, null Setup — aber Daten beim US-Anbieter (CLOUD Act), wenig Kontrolle.

- Kein Setup erforderlich
- Beste Modellqualität
- Daten außerhalb EU-Jurisdiktion

2

Managed

Langdock · DeutschlandGPT · DeepMask · plusAI

Fertige UI + kuratierte Modelle auf EU-/DE-Infrastruktur, DSGVO-konform, Connectors (SharePoint/Drive), wenig Setup.

- DSGVO-konforme Infrastruktur
- Connectors (SharePoint / Drive)
- Geringer Betriebsaufwand

Oft der pragmatische Sweet Spot für den Mittelstand.

3

Self-hosted

vLLM / aki.io / StackIT + LiteLLM Gateway + Open WebUI + eigene Vektor-DB

Maximale Kontrolle & echte Souveränität, volles Customizing aller Schichten — aber mehr Betriebsaufwand und eigenes Know-how erforderlich.

- Freie Modellwahl & Inferenz
- Eigene UI & Vektor-DB
- Maximale Kontrolle, mehr Aufwand

Dimension	Turnkey	Managed	Self-hosted
Aufwand	Keiner	Gering	Hoch
Souveränität	Kritisch	Gut	Maximal
Kosten	Per-Seat	Per-Seat	Token/Infra

Souveränität: Abstufung innerhablb der EU



Für eine Kanzlei gilt: **Deployment eher rechts auf der Achse wählen.** Wichtig: **EU-Region ≠ EU-Jurisdiktion** — US-Anbieter mit EU-Rechenzentren unterliegen weiterhin dem CLOUD Act und können zur Herausgabe von Daten verpflichtet werden.



Europäische Modelle & Anbieter

Souveränität endet nicht beim Hosting — auch das Modell zählt.

1

Mistral 🇫🇷

Leistungsstarke offene Modelle aus Frankreich

2

Aleph Alpha & Black Forest Labs 🇩🇪

Aleph Alpha: Sprache · FLUX: Bildgenerierung

3

Apertus 🇨🇭

Vollständig offen

Souveräne Infrastruktur

StackIT (Schwarz) · aki.io (EU-API) · noirdoc (DSGVO-Proxy)

Offene Gewichte (EU-hostbar): **Llama · Qwen · DeepSeek**

Kosten & Break-Even

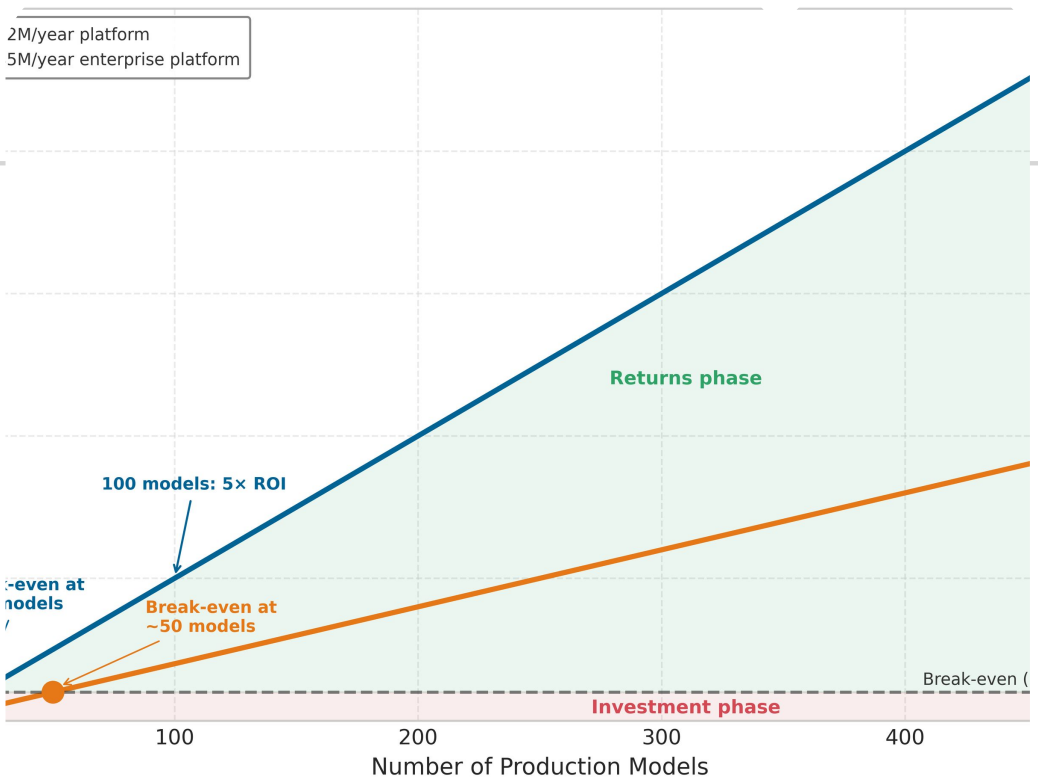
Break-Even

Ab welchem Volumen wird Eigenbetrieb günstiger als Abo/API?

Quelle: Pan, Chodnekar et al., CMU 2025, arXiv 2509.18101

API-Kosten

Linear steigend mit Nutzung



On-Prem

Flach nach Anfangsinvestition

Preismodelle

Per-Seat

Turnkey / Managed

Per-Token

Self-hosted via API

Per-GPU-Stunde

Self-hosted on-prem

Hybrid

Commitment-Modelle

TCO = Hardware + Strom + Personal + Abschreibung

Betrieb: Security & Observability

Ohne Monitoring kein echter Produktivbetrieb.

Security & Guardrails

noirdoc

PII-Maskierung vor dem Modell

Llama Guard

Inhaltsfilterung

NeMo Guardrails

Regelbasierte Absicherung

Lakera

Prompt Injection Schutz

Observability

Langfuse

Open Source, EU — Tracing & Evals

Helicone

Kosten-Tracking

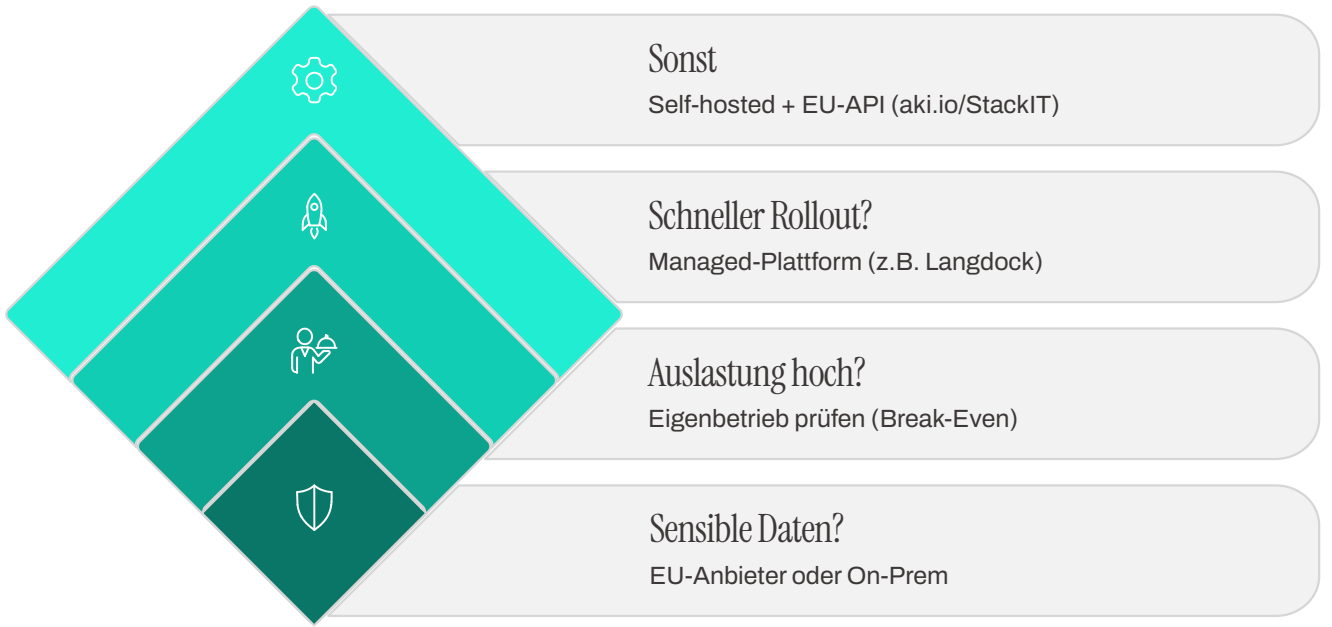
Phoenix / Arize

ML-Observability

OpenLLMetry

OpenTelemetry für LLMs

Make or Buy – Entscheidungsframework



Sonst
Self-hosted + EU-API (aki.io/StackIT)

Schneller Rollout?
Managed-Plattform (z.B. Langdock)

Auslastung hoch?
Eigenbetrieb prüfen (Break-Even)

Sensible Daten?
EU-Anbieter oder On-Prem

Die vier Leitfragen

Sensible Daten?
→ EU-Anbieter / On-Prem

Hohe Auslastung?
→ Eigenbetrieb prüfen

Schneller Rollout?
→ Managed-Plattform

Sonst
→ Self-hosted + EU-API



Takeaways & Ressourcen

Der Stack ist eine Landkarte

Jedes Tool sitzt auf einer Ebene — kein Tool ist überall.

„OpenAI-kompatibel" macht Anbieter austauschbar

Nur `base_url` + Key tauschen — Souveränität wird praktisch machbar.

Souveränität = EU-Anbieter + EU-Recht

Nicht nur EU-Server — Jurisdiktion folgt dem Unternehmen.

Aufgabe: Baut den Stack für die Kanzlei

01

Betriebsmodell wählen

Turnkey / Managed / Self-hosted — mit Begründung

02

Jede Schicht festlegen

Modell · Inferenz · Gateway · UI · RAG · Datenschutz

03

Jede Wahl begründen

An einer Randbedingung: §203 · DSGVO · EU-only · Budget

04

Break-Even rechnen

Abo/API pro Jahr vs. On-Prem-Kapital (Annahme: 200 Nutzer, 500k Tokens/Tag)