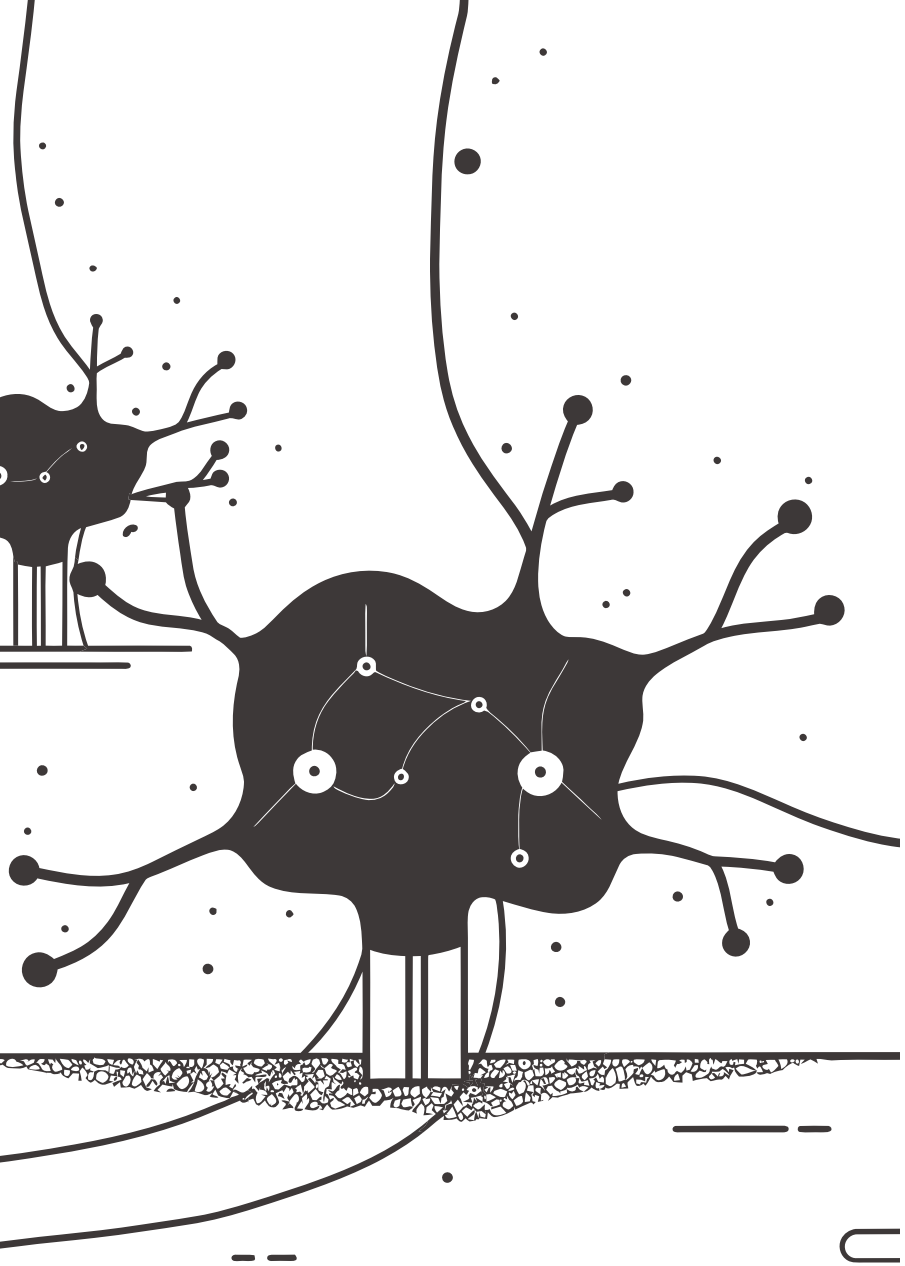
FUTUREWAY
KI INSTITUT

Modul 1: KI-Grundlagen

Lektion 13: Agent Observability

KI Automations Spezialist

Juli 2026



Agent Observability

Tracing, Logging & Evaluation in der Praxis

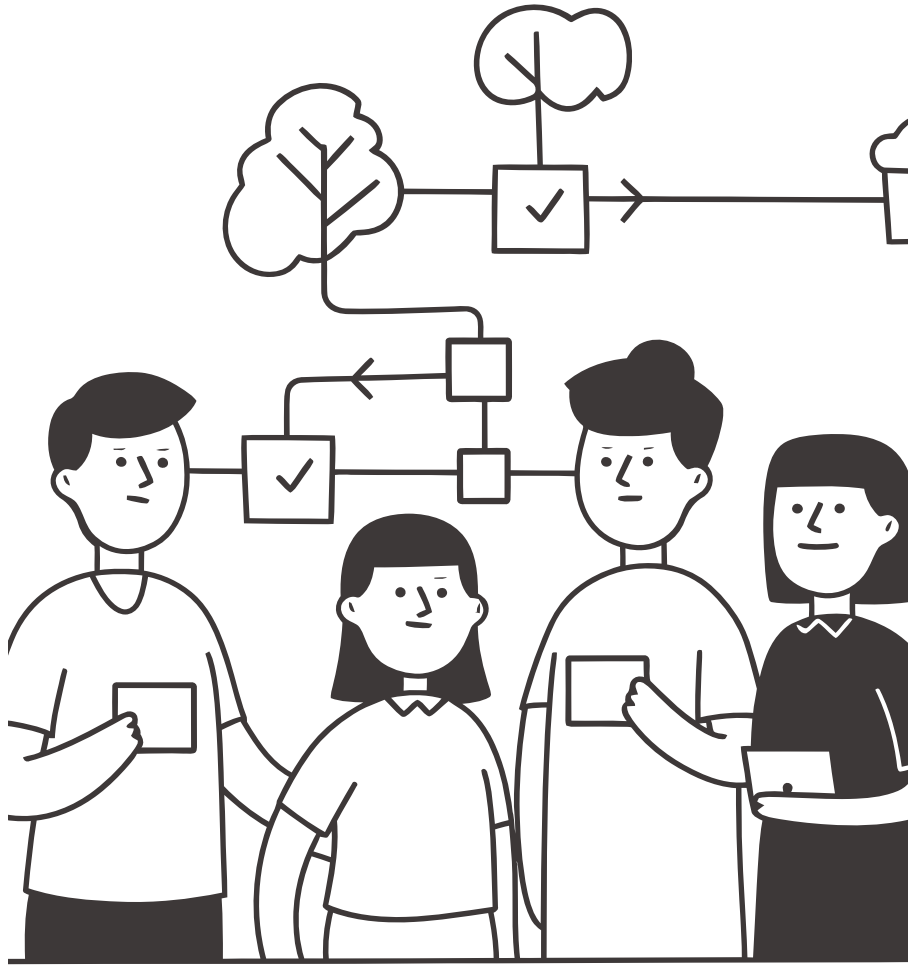
Warum Observability für Agenten?

KI-Agenten sind **probabilistisch und mehrstufig**: Sie rufen Tools auf, treffen Entscheidungen und laufen in Schleifen.

Fehler tauchen nicht als klassische Errors auf, sondern **kaskadieren** durch die Folgeschritte

Dieselbe Eingabe kann unterschiedliche Ergebnisse liefern

Klassisches Monitoring (Uptime, Latenz) reicht nicht – es fehlt die Dimension: **"War die Antwort gut?"**



Einordnung: Observability, Monitoring, Logging & Tracing

Vier oft verwechselte Begriffe – auf unterschiedlichen Ebenen:

Observability

der Oberbegriff und das Ziel: von außen verstehen, was innen passiert. Monitoring, Logging & Tracing sind die Mittel dorthin.

Monitoring

vorab definierte Signale überwachen (Fehlerrate, Latenz, Kosten) mit Schwellwerten und Alerts → "läuft das Erwartete normal?"

Logging

einzelne, zeitgestempelte Ereignisse → die **Punkte**

Tracing

verbindet die Ereignisse zu einem durchgehenden Pfad → die **Linie**

Merksatz: Monitoring sagt dir, **DASS** etwas kaputt ist. Observability hilft dir zu verstehen, **WARUM**.

Für Agenten reichen diese klassischen Säulen nicht – weil der Output probabilistisch ist. Deshalb kommt eine vierte Dimension dazu: **Evaluation**.

Die vier Bausteine im Überblick



Tracing

Was ist passiert? (der komplette Ablauf)



Evaluation

War es gut? (die neue, agent-spezifische Dimension)



Logging

Was wurde gesendet und empfangen?



Cost & Latency

Was hat es gekostet und wie lange gedauert?

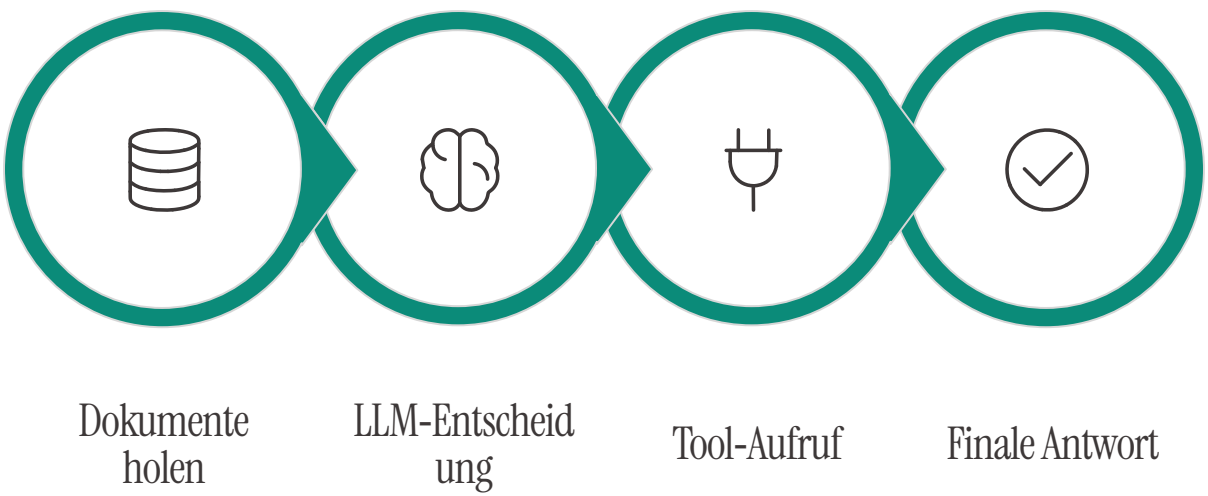
Zusammen ergeben sie das vollständige Bild eines Agenten-Laufs.

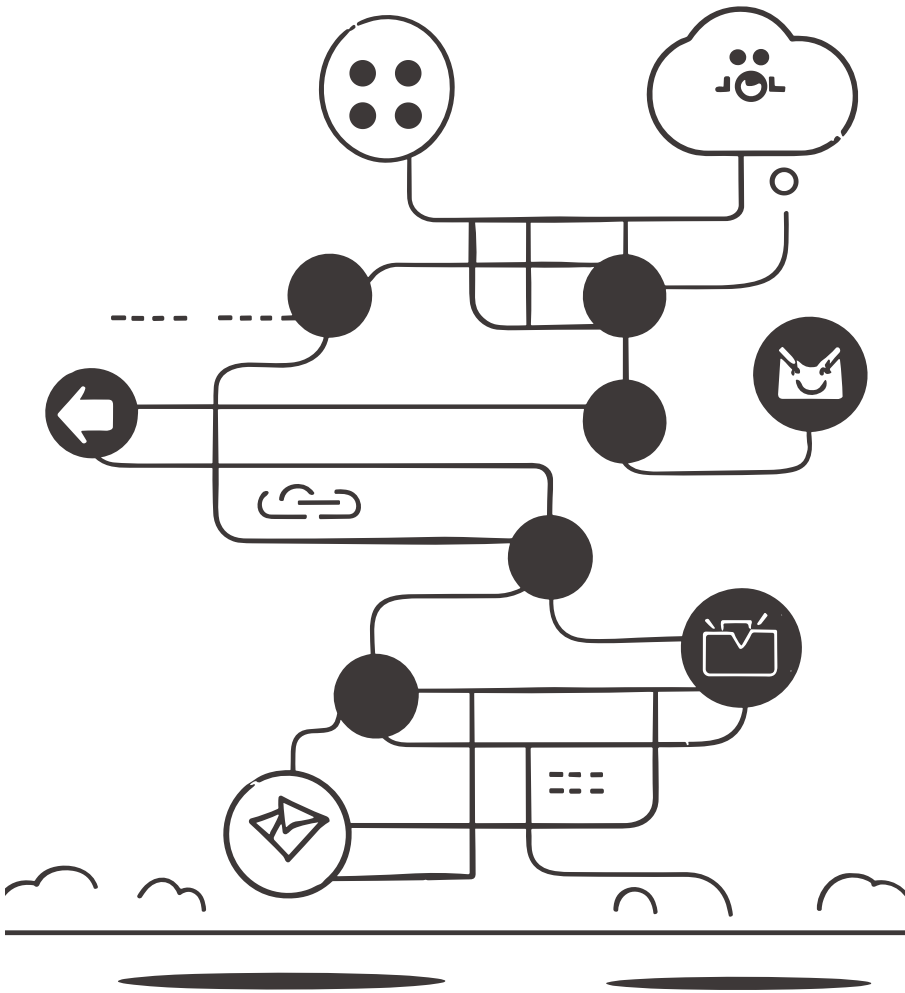
Tracing erklärt

Ein **Trace** = eine End-to-End-Anfrage. Darin verschachtelte **Observations**:

→ LLM-Call, Tool-Call, Retrieval, Entscheidung – jeder Schritt einzeln inspizierbar

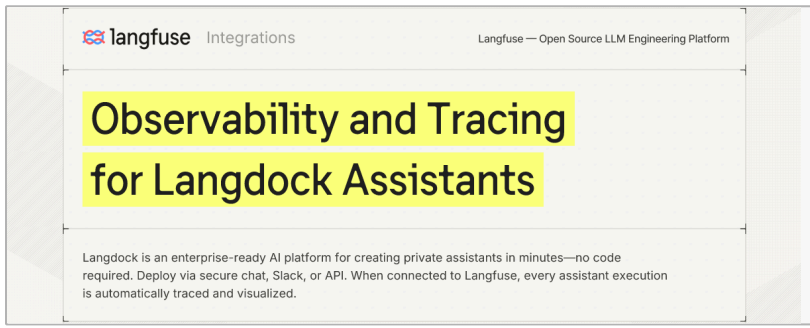
Hierarchisch dargestellt als Baum, mit Reihenfolge und Timing





Beispiel-Ablauf: Retrieve (Dokumente holen) → LLM-Entscheidung → Tool-Aufruf → finale Antwort

Aufgabe: Langfuse + Langdock



langfuse.com

Observability and Tracing for Langdock Assistants – Langfuse

Langdock is an enterprise-ready AI platform for creating private assistants in minutes—no code required. Deploy via secure chat, Slack, or API. When connected to Langfuse, every assistant…

Ergebnis: Alle Konversationen streamen automatisch als Traces nach Langfuse und werden dort visualisiert.

Was man dann in Langfuse sieht



Verschachtelte Traces

Modell, Provider und jeder Schritt im Detail



Token-Verbrauch & Kosten

pro Aufruf



Latenz pro Schritt

wo ist der Flaschenhals?



Tool-Aufrufe

welches Tool, mit welchen Argumenten



Agent-Graph-View

Nachvollziehbarkeit der Vorgehensweise