FUTUREWAY
KI INSTITUT

KI AUTOMATIONS SPEZIALIST · TAG 11 · 12.10.2026 · LEKTION 10

KI-Infra-struktur

Welcher Stack ist der richtige?

Das Lernheft zur Lektion: was technisch hinter KI im Unternehmen steckt – Modelle, Server, Schnittstellen, Plattformen – und wie man zwischen fertigem Dienst, verwalteter Plattform und Eigenbetrieb entscheidet.

Zum Lesen und Merken – ohne Technik-Vorwissen, mit freiwilligen Übungen am Ende.

DIE DREI BETRIEBSMODELLE · FOLIE 12



Turnkey
fertig nutzen, z. B. ChatGPT

Managed
verwaltete Plattform, z. B. Langdock

Self-hosted
alles selbst betreiben

BEVOR ES LOSGEHT

So liest man dieses Heft

Eine Seite, ein Gedanke

Viele Fachwörter heute – jedes wird in einem Satz erklärt.

Unten der Merksatz

Der schwarze Kasten am Ende jeder Seite ist das, was hängen bleiben soll.

Freiwillig üben

Am Ende Übungen für Langdock – Rechnen, Vergleichen, Entscheiden.

INHALT

01	Der Stack als Landkarte	FOLIEN 2, 18
02	Warum eigene Infrastruktur?	FOLIE 3
03	Regeln und Standards	FOLIE 3
04	Wo das Modell läuft	FOLIE 4
05	Grafikspeicher und Quantisierung	FOLIE 5
06	Wie schnell? Drei Kennzahlen	FOLIE 6
07	Vier API-Typen	FOLIE 7
08	Bündeln, steuern, bedienen	FOLIEN 8–10
09	Drei Betriebsmodelle	FOLIEN 11–12
10	Souveränität in Stufen	FOLIEN 13–14
11	Kosten und Betrieb	FOLIEN 15–16
12	Unser Fall: der Kanzlei-Stack	FOLIEN 17, 19

UNSER FALL DURCH DAS HEFT

EINE KANZLEI MIT 200 LEUTEN (AUSGEDACHT, WIE AUF FOLIE 19)

„Wir wollen KI nutzen – aber Mandantendaten sind streng geheim. Was brauchen wir, und was bauen wir selbst?“

Kapitel für Kapitel sammelt das Heft, was die Kanzlei für ihre Entscheidung wissen muss. In Kapitel 12 steht ihr Stack – mit Begründung und grober Kostenrechnung.

MERKSATZ

Die richtige KI-Technik hängt an den Daten, dem Budget und dem Aufwand.

01

KAPITEL 1 FOLIE 2 FOLIE 18

Der Stack als Landkarte

Hinter jedem KI-Werkzeug steckt ein Stapel aus Bausteinen – der „Stack“. Jedes Werkzeug sitzt auf einer Ebene, keines ist überall. Von unten nach oben:

Hardware Grafikkarten, Server	Die Rechner, auf denen alles läuft – meist mit starken Grafikkarten.
Modell das „Gehirn“	Das Sprachmodell selbst, z. B. von Mistral, Meta oder OpenAI.
Inferenz / Serving Kapitel 4	Das Programm, das das Modell betreibt und Antworten erzeugt.
Gateway Kapitel 8	Die Schaltzentrale: Schlüssel, Budgets, Ausweichmodelle, Protokolle.
Oberfläche Kapitel 8	Das Chatfenster, in dem Menschen arbeiten.
RAG / Wissensspeicher Tag 4	Die Vektor-Datenbank mit den eigenen Dokumenten.
Schutz und Überwachung Kapitel 11	Datenschutz-Filter, Sicherheitsregeln, Kosten- und Fehlerüberwachung.

? Die zwei Leitfragen von Folie 2: **Was brauche ich technisch? Wie viel baue ich selbst?**

MERKSATZ

Der Stack ist eine Landkarte – jedes Werkzeug hat seine Ebene.

KAPITEL 2 FOLIE 3

02 Warum eigene Infrastruktur?

Vier Gründe sprechen dafür, nicht alles einem großen Anbieter zu überlassen.

Datensouveränität

Daten bleiben im Haus

Daten liegen auf eigenen oder kontrollierten Servern.

Compliance

Regeln einhalten

Wer die Technik kontrolliert, kontrolliert die Einhaltung der Vorschriften.

Kein Lock-in

unabhängig bleiben

Volle Wechselmöglichkeit, keine Abhängigkeit von US-Anbietern.

Planbare Kosten

rechnen statt raten

Kosten für Rechenleistung statt eines Preises pro Person.

„Server in Frankfurt“ ≠ souverän

Der US-amerikanische **CLOUD Act** gilt für US-Konzerne weltweit – unabhängig davon, wo der Server steht. US-Behörden können also auch Daten aus deutschen Rechenzentren eines US-Anbieters verlangen.

UNSER FALL

Für die Kanzlei ist das der Knackpunkt: Mandantendaten dürfen nicht in die Hände Dritter geraten – auch nicht über den Umweg eines ausländischen Gesetzes.

MERKSATZ

Es zählt nicht nur, wo der Server steht – sondern wem er gehört.

03

KAPITEL 3 FOLIE 3

Regeln und Standards

Fünf Abkürzungen tauchen in jedem Gespräch über KI-Infrastruktur auf. Ein Satz zu jeder:

DSGVO EU	Datenschutz-Grundverordnung: Regeln für den Umgang mit personenbezogenen Daten in der EU.
EU AI Act EU	Regelt KI nach Risiko – je riskanter der Einsatz, desto strenger die Pflichten. Gilt schrittweise ab 2025.
BSI C5 Deutschland	Standard des Bundesamts für Sicherheit in der Informationstechnik für sichere Cloud-Dienste.
ISO 27001 international	Internationaler Standard für ein Managementsystem der Informationssicherheit.
SOC 2 USA	US-Prüfstandard, wie Dienstleister mit Kundendaten umgehen.

Für die Aufgabe wichtig: §203 StGB

Der Paragraf schützt Berufsgeheimnisse – etwa von Anwälten, Steuerberatern und Ärzten. Wer solche Geheimnisse unbefugt weitergibt, macht sich strafbar. Darum muss eine Kanzlei bei jedem Dienstleister genau prüfen, wer an die Daten kommen könnte.

! Ein Zertifikat ist kein Freifahrtschein: Es zeigt, dass Prozesse geprüft wurden – **nicht**, welchem Recht der Anbieter unterliegt.

MERKSATZ

DSGVO schützt Daten, AI Act regelt KI, Zertifikate zeigen geprüfte Sicherheit.

04

KAPITEL 4 FOLIE 4

Wo das Modell läuft

Ein Sprachmodell ist zunächst nur eine große Datei. Damit es Antworten gibt, braucht es ein Programm, das es betreibt – eine „Serving-Engine“.

Für Server

Hohe Leistung, viele Nutzer gleichzeitig:

- **vLLM** – sehr verbreitet
- **SGLang**
- Lösungen von **NVIDIA**

Für den eigenen Rechner

Zum Ausprobieren, oft mit wenigen Klicks:

- **Ollama**
- **llama.cpp**
- **LM Studio** und **GPT4All** – mit Oberfläche

LOKAL AM LAPTOP

gut zum Lernen

Kleine Modelle, eine Person, keine Daten verlassen den Rechner.

AUF DEM SERVER

für das ganze Team

Große Modelle, viele Menschen gleichzeitig – braucht Fachwissen im Betrieb.

MERKSATZ

Modell = die Datei. Serving-Engine = das Programm, das sie zum Sprechen bringt.

05

KAPITEL 5 FOLIE 5

Grafikspeicher und Quantisierung

Das Nadelöhr beim Eigenbetrieb ist der Grafikspeicher (VRAM). Das Modell muss komplett hineinpassen.

Die Faustregel von Folie 5

In 16 Bit (FP16) braucht ein Modell etwa **2 GB Grafikspeicher pro Milliarde Parameter**.

7–8 Milliarden Parameter	**Laptop / Grafikkarte**
70 Milliarden	**mehrere Grafikkarten**
über 100 Milliarden	**Rechner-Verbund**

QUANTISIERUNG: DIE ZAHLEN VERKÜRZEN

Die Gewichte im Modell werden von 16 auf 8 oder 4 Bit gekürzt – wie ein Foto, das stärker komprimiert wird, aber fast gleich aussieht.

```
70-Milliarden-Modell
16 Bit:  70 × 2 GB   = ~140 GB
 8 Bit:  70 × 1 GB   =  ~70 GB
 4 Bit:  70 × 0,5 GB =  ~35 GB  + Puffer im Betrieb → laut Folie ~40 GB, kaum Qualitätsverlust
```

lokal mit llama.cpp / Ollama	**GGUF**
Grafikkarte, 4 Bit	**GPTQ**
qualitätsschonend, mit vLLM	**AWQ**
moderne Grafikkarten, kaum Verlust	**FP8**

MERKSATZ

2 GB je Milliarde – und Quantisierung teilt das bis durch vier.

06

KAPITEL 6 FOLIE 6

Wie schnell? Drei Kennzahlen

Ob ein KI-Dienst im Alltag angenehm ist, zeigen drei Zahlen. Bild dazu: ein Restaurant.

1

TTFT – Time to First Token

✓ Zeit bis zum ersten Wort. Die gefühlte Reaktionszeit – wie schnell der Kellner an den Tisch kommt.

2

Tokens pro Sekunde und Latenz

✓ Wie flüssig der Text erscheint – wie zügig die Gänge nacheinander kommen.

3

Durchsatz und Parallelität

✓ Wie viele Menschen gleichzeitig bedient werden – und damit die Kosten pro Person.

Der Zielkonflikt

Niedrige Wartezeit für jeden einzelnen ↔ viele Nutzer gleichzeitig – selten beides zugleich. Wie in der Küche: Entweder jeder Gast wird sofort bedient, oder viele werden effizient bedient.

UNSER FALL Für 200 Leute in der Kanzlei zählt vor allem, dass auch zur Stoßzeit alle flüssig arbeiten können – also Durchsatz.

MERKSATZ

Schnell für einen oder günstig für viele – man muss abwägen.

07

KAPITEL 7 FOLIE 7

Vier API-Typen

Über APIs (Tag 10) sprechen Programme mit dem Modell. Vier Arten gibt es:

1

Completion

Text rein, Text raus: „Die Hauptstadt von Bayern ist“ → „München.“ Heute veraltet.

2

Chat Completions

Nachrichten mit Rollen (system, user, assistant). Der Standard – mit Werkzeugen und Streaming.

3

Responses / Messages

Die neue Generation von OpenAI und Anthropic: Werkzeuge, Zustand, Agenten.

4

Embeddings

Text → Zahlenreihe (Vektor). Grundlage für Suche und RAG (Tag 4).

„OPENAI-KOMPATIBEL“ – DER UNIVERSAL-STECKER

HEUTE BEI ANBIETER A

```
base_url =
https://api.anbieter-
a.example/v1
api_key  = [Schlüssel A]
model    = modell-a
```

MORGEN BEI ANBIETER B (Z. B. AUS DER EU)

```
base_url =
https://api.anbieter-
b.example/v1
api_key  = [Schlüssel B]
model    = modell-b
```

MERKSATZ

Anbieter wechseln = Adresse und Schlüssel tauschen. So wird Souveränität machbar.

08

KAPITEL 8 FOLIE 8 FOLIE 9 FOLIE 10

Bündeln, steuern, bedienen

Zwischen Modell und Mensch sitzen drei Bausteine, die man kaufen oder selbst betreiben kann.

1 Aggregatoren – viele Anbieter, ein Zugang

✓ Je nach Kosten, Verfügbarkeit und Spezialgebiet das passende Modell wählen, oft mit Überwachung und automatischem Ausweichen. Z. B. OpenRouter, together.ai, Requesty, Fireworks AI, Azure AI Foundry, IONOS, STACKIT, AKI.

2 Gateways – die Schaltzentrale

✓ Schlüssel verwalten, Budgets und Grenzen setzen, bei Ausfall auf ein anderes Modell umschalten, jede Anfrage protokollieren. Z. B. LiteLLM, Portkey, Kong, Cloudflare.

3 Oberflächen und Wissensspeicher

✓ Selbst betreibbare Chat-Oberflächen: Open WebUI (am beliebtesten, mit RAG), AnythingLLM, LibreChat, Jan. Vektor-Datenbanken: Qdrant, Weaviate, Chroma, pgvector.

Bild dazu

Aggregator = Großhändler mit vielen Lieferanten. Gateway = Pförtner mit Schlüsselbrett und Kassenbuch. Oberfläche = der Laden, in dem man einkauft.

In Langdock schon drin

Eine Managed-Plattform liefert Oberfläche, Modellauswahl, Wissensbasen und Verwaltung aus einer Hand – genau diese Bausteine.

MERKSATZ

Aggregator bündelt, Gateway steuert, Oberfläche bedient.

09

KAPITEL 9 FOLIE 11 FOLIE 12

Drei Betriebsmodelle

Die wichtigste Entscheidung: Wie viel nimmt man fertig – und wie viel betreibt man selbst?

	Turnkey	Managed	Self-hosted
BEISPIELE	ChatGPT, Claude, Gemini, Copilot	Langdock, DeutschlandGPT, DeepMask, plusAI	vLLM, aki.io oder StackIT + LiteLLM + Open WebUI + eigene Vektor-DB
STÄRKE	sofort nutzbar, beste Modelle	fertige Oberfläche auf EU-Infrastruktur, DSGVO-konform, Anbindung an SharePoint/Drive	maximale Kontrolle, alles anpassbar
SCHWÄCHE	Daten beim US-Anbieter (CLOUD Act), wenig Kontrolle	weniger Freiheit als Eigenbetrieb	viel Aufwand, eigenes Fachwissen nötig
AUFWAND	keiner	gering	hoch
SOUVERÄNITÄT	kritisch	gut	maximal
KOSTEN	pro Person	pro Person	Tokens / Infrastruktur

Laut Folie 12

Managed ist oft der pragmatische Mittelweg für den Mittelstand – auf Folie 11 stehen dafür z. B. nexos.ai, DeutschlandGPT, DeepMask, Langdock und BasePeak.

MERKSATZ

Turnkey = bequem, Managed = Mittelweg, Self-hosted = volle Kontrolle.

10

KAPITEL 10 FOLIE 13 FOLIE 14

Souveränität in Stufen

Souveränität ist kein Ja oder Nein. Folie 13 zeigt vier Stufen – je weiter unten, desto mehr Kontrolle:

SaaS wenig Kontrolle	Ein gemeinsamer Dienst für alle Kunden.
Single-Tenant	Eine eigene Instanz beim Anbieter – nur für die eigene Firma.
Bring Your Own Cloud	Die Software läuft in der eigenen Cloud-Umgebung der Firma.
On-Prem volle Kontrolle	Alles läuft im eigenen Haus auf eigenen Servern.

EU-Region ≠ EU-Recht

US-Anbieter mit EU-Rechenzentren unterliegen weiter dem CLOUD Act. Für eine Kanzlei gilt laut Folie: eher die kontrollierten Stufen wählen.

AUCH DAS MODELL ZÄHLT (FOLIE 14)

Frankreich – starke offene Modelle	**Mistral**	Deutschland – Sprache · Bilder (FLUX)	**Aleph Alpha · Black Forest Labs**
Schweiz – vollständig offen	**Apertus**	souveräne Infrastruktur	**StackIT · aki.io · noirdoc**

Offene Modelle wie Llama, Qwen oder DeepSeek lassen sich ebenfalls in der EU betreiben.

MERKSATZ

Souverän = EU-Anbieter + EU-Recht – nicht nur EU-Server.

11

KAPITEL 11 FOLIE 15 FOLIE 16

Kosten und Betrieb

API-Kosten steigen mit jeder Nutzung. Eigener Betrieb kostet viel am Anfang – danach bleibt die Kurve flach. Wo sich die Linien kreuzen, liegt der Break-Even.

Turnkey und Managed **pro Person**	Self-hosted über eine API **pro Token**
eigene Server **pro GPU-Stunde**	Mischformen mit festen Zusagen **hybrid**

Die Gesamtkosten (TCO)

Hardware + Strom + Personal + Abschreibung – oft ist das Personal der größte Posten.

OHNE ÜBERWACHUNG KEIN ECHTER BETRIEB (FOLIE 16)

Schutz

- **noirdoc** – persönliche Daten maskieren, bevor sie zum Modell gehen
- **Llama Guard** – Inhalte filtern
- **NeMo Guardrails** – Regeln setzen
- **Lakera** – Schutz vor Prompt Injection

Überwachung

- **Langfuse** – Open Source aus der EU, Abläufe und Tests
- **Helicone** – Kosten im Blick
- **Phoenix / Arize**, **OpenLLMetry**

Quelle der Break-Even-Grafik auf Folie 15: Pan, Chodnekar et al., CMU 2025 (arXiv 2509.18101).

MERKSATZ

Viel Nutzung spricht für Eigenbetrieb – wenn man Personal und Strom mitrechnet.

12

KAPITEL 12 FOLIE 17 FOLIE 19

Unser Fall: der Kanzlei-Stack

Die vier Leitfragen von Folie 17 führen zur Entscheidung – angewendet auf die Kanzlei aus der Aufgabe.

Sensible Daten? ja – §203	→	EU-Anbieter oder eigener Betrieb
Hohe Auslastung? 200 Leute	→	Eigenbetrieb prüfen (Break-Even rechnen)
Schneller Start?	→	Managed-Plattform wie Langdock
Sonst	→	selbst betreiben mit EU-API (aki.io, StackIT)

BREAK-EVEN – SO WIRD GERECHNET (BEISPIELZAHLEN, AUSGEDACHT)

Managed, pro Person

`200 Personen × 25 € × 12 Monate`

60.000 € / Jahr

API, pro Token

`500.000 Tokens × 365 Tage = 182,5 Mio. × 2 € je Mio.`

365 € / Jahr

`+ Oberfläche, Gateway, Betrieb`

Eigene Server

`80.000 € ÷ 3 Jahre + 3.000 € Strom + 25.000 € Personal`

≈ 54.700 € / Jahr

! Die Rechnung zeigt: Die Tokens selbst sind oft billig – **teuer sind Personal, Betrieb und Sicherheit.** Für die Aufgabe echte Preise recherchieren, nicht diese Beispielzahlen nehmen.

MERKSATZ

Betriebsmodell wählen, jede Schicht festlegen, jede Wahl begründen – dann rechnen.

ZUM WIEDERHOLEN

Die Lektion auf einer Seite

DIE FORMEL

Souveränität = EU-Anbieter + EU-Recht – nicht nur EU-Server.

DER STACK

Hardware · Modell · Serving · Gateway · Oberfläche · RAG · Schutz und Überwachung

WARUM EIGENE INFRASTRUKTUR?

Daten · Compliance · kein Lock-in · planbare Kosten · CLOUD Act beachten

GRAFIKSPEICHER

~2 GB je Milliarde Parameter (16 Bit) · Quantisierung auf 8 oder 4 Bit

KENNZAHLEN

Zeit bis zum ersten Wort · Tempo · Nutzer gleichzeitig

APIS

Chat Completions ist Standard · „OpenAI-kompatibel“: Adresse + Schlüssel tauschen

BAUSTEINE

Aggregator bündelt · Gateway steuert · Oberfläche bedient

BETRIEBSMODELLE

Turnkey · Managed (Mittelweg) · Self-hosted

KOSTEN

pro Person · pro Token · pro GPU-Stunde · TCO = Hardware + Strom + Personal + Abschreibung

MAKE OR BUY

Sensible Daten → EU/On-Prem · hohe Auslastung → Eigenbetrieb prüfen · schnell → Managed · sonst → Self-hosted + EU-API

Ü

FREIWILLIG · JE ETWA 5–10 MINUTEN

Üben in Langdock (1)

Rechnen, vergleichen, entscheiden – mit Langdock als Sparringspartner. Für aktuelle Preise und Anbieter die Websuche einschalten.

ÜBUNG 1 Welche Schicht ist das?

5 Min

> Ordne diese Werkzeuge einer Schicht im KI-Stack zu (Modell, Serving, Gateway, Oberfläche, Vektor-Datenbank, Schutz, Überwachung) und erkläre jedes in einem Satz: Mistral, vLLM, Ollama, LiteLLM, Open WebUI, Qdrant, Langfuse, Lakera, noirdoc, Langdock.

Darauf achten: Wo sortiert die KI Langdock ein – und warum passt es auf mehrere Ebenen?

ÜBUNG 2 Passt das Modell auf den Rechner?

5 Min

> Wie viel Grafikspeicher brauchen die Gewichte eines Modells mit 8, 32 und 70 Milliarden Parametern – jeweils in 16, 8 und 4 Bit? Nutze die Faustregel 2 GB pro Milliarde Parameter in 16 Bit. Antworte als Tabelle und sag, welches davon auf eine Grafikkarte mit 24 GB passt.

Selbst nachrechnen: 8B in 4 Bit ≈ 4 GB, 32B in 4 Bit ≈ 16 GB, 70B in 4 Bit ≈ 35 GB (plus Puffer).

ÜBUNG 3 Ist das souverän?

5 Min

> Erkläre meinem Team in höchstens 6 Sätzen, warum „unsere Daten liegen in einem Rechenzentrum in Frankfurt“ nicht automatisch heißt, dass sie vor dem Zugriff ausländischer Behörden geschützt sind. Nenne 3 Fragen, die wir einem KI-Anbieter stellen sollten.

Druck & Vertrieb: Kundendaten im Angebotsprozess · **Business & Website:** Mitarbeiterdaten in der Teamleitung · **Video & Design:** unveröffentlichte Kampagnen

FREIWILLIG · JE ETWA 5–10 MINUTEN

Üben in Langdock (2)

ÜBUNG 4 Break-Even rechnen

10 Min

> Rechne für eine Firma mit 200 Personen grob die Jahreskosten von drei Wegen: 1) Managed-Plattform zu 25 € pro Person und Monat, 2) eigene Server mit 80.000 € Anschaffung (3 Jahre), 3.000 € Strom und 25.000 € Personal pro Jahr, 3) API mit 500.000 Tokens pro Tag zu 2 € je Million Tokens plus 20.000 € pro Jahr für Betrieb und Oberfläche. Zeige jeden Rechenschritt und sag, ab wie vielen Personen sich Weg 2 gegenüber Weg 1 lohnt.

Darauf achten: Alle Zahlen sind ausgedacht – es geht um den Rechenweg. Stimmt das Ergebnis mit eigener Rechnung überein?

ÜBUNG 5 Make or Buy für die eigene Firma

10 Min

> Geh mit mir die vier Leitfragen durch – sensible Daten, Auslastung, Tempo beim Start, Budget – für eine ausgedachte Firma aus meinem Bereich [Bereich]. Stelle mir zuerst 4 Rückfragen, empfiehl dann Turnkey, Managed oder Self-hosted und begründe in 5 Sätzen.

Darauf achten: Begründet die KI mit den Leitfragen – oder nur mit allgemeinen Vorteilen?

BONUS Der Kanzlei-Stack in Kurzform

10 Min

> Baue einen KI-Stack für eine ausgedachte Kanzlei mit 200 Personen. Randbedingungen: Schweigepflicht nach §203 StGB, DSGVO, nur EU-Anbieter, begrenztes Budget. Lege jede Schicht fest (Modell, Inferenz, Gateway, Oberfläche, RAG, Datenschutz) und begründe jede Wahl in einem Satz an einer Randbedingung. Als Tabelle.

Tipp: Websuche einschalten und prüfen lassen, ob die genannten Anbieter wirklich in der EU sitzen.

?

ZUM SELBST-ABFRAGEN

Zwölf Merkfragen – mit Antwort

Frage lesen, kurz selbst überlegen, dann die Antwort darunter lesen. Online gibt es dieselben Fragen als Lernkarten zum Umdrehen.

FRAGE 01

Was ist ein KI-Stack?

Der Stapel aus Bausteinen: Modell, Server, Schnittstelle, Oberfläche, Wissensspeicher, Schutz und Überwachung.

FRAGE 02

Warum ist „Server in Frankfurt“ nicht automatisch souverän?

Wegen des CLOUD Act: US-Konzerne müssen Daten weltweit herausgeben – egal wo der Server steht.

FRAGE 03

Nenne zwei Gründe für eigene Infrastruktur.

Datensouveränität, Kontrolle über Compliance, kein Lock-in, planbare Kosten.

FRAGE 04

Faustregel für den Grafikspeicher?

In 16 Bit rund 2 GB pro Milliarde Parameter – ein 8B-Modell also etwa 16 GB.

FRAGE 05

Was bringt Quantisierung?

Weniger Speicher bei kaum Qualitätsverlust: 70B schrumpft von ~140 GB auf ~40 GB.

FRAGE 06

Was misst TTFT?

Die Zeit bis zum ersten Wort – die gefühlte Reaktionszeit.

FRAGE 07

Was heißt „OpenAI-kompatibel“?

Gleiche Schnittstelle – ein Anbieterwechsel heißt nur base_url und Key tauschen.

FRAGE 08

Wofür ist ein Gateway da?

Schlüssel, Budgets, Grenzen, Ausweichmodelle und Protokolle an einer Stelle.

FRAGE 09

Die drei Betriebsmodelle?

Turnkey (fertig, US), Managed (z. B. Langdock, EU) und Self-hosted (alles selbst).

FRAGE 10

EU-Region oder EU-Jurisdiktion – was zählt für Souveränität?

Die Jurisdiktion: EU-Anbieter unter EU-Recht, nicht nur EU-Server.

FRAGE 11

Woraus besteht die TCO?

Hardware + Strom + Personal + Abschreibung.

FRAGE 12

Die vier Leitfragen für Make or Buy?

Sensible Daten? Hohe Auslastung? Schneller Start? Sonst: selbst betreiben mit EU-API.

Aa

ZUM NACHSCHLAGEN

Die Wörter des Tages

Stack
Der Stapel aus Bausteinen, die zusammen ein KI-System ergeben: Modell, Server, Schnittstelle, Oberfläche, Speicher, Schutz.

Souveränität
Volle Kontrolle über Daten und Technik – nach EU-Recht, ohne Zugriff ausländischer Behörden.

CLOUD Act
US-Gesetz: US-Firmen müssen Daten auch aus ausländischen Rechenzentren herausgeben.

Serving-Engine
Programm, das ein Sprachmodell auf einem Rechner betreibt, z. B. vLLM oder Ollama.

VRAM
Grafikspeicher – reicht er nicht, läuft das Modell nicht.

Quantisierung
Zahlen im Modell verkürzen (16 → 8 → 4 Bit), damit es weniger Speicher braucht.

TTFT
Time to First Token: Zeit bis zum ersten Wort der Antwort.

OpenAI-kompatibel
Gleiche Schnittstelle wie OpenAI – Anbieterwechsel durch Tausch von Adresse und Schlüssel.

Gateway
Schaltzentrale vor den Modellen: Schlüssel, Budgets, Ausweichmodelle, Protokolle.

Turnkey / Managed / Self-hosted
Fertig nutzen · verwaltete Plattform · alles selbst betreiben.

Break-Even
Der Punkt, ab dem Eigenbetrieb günstiger ist als Abo oder API.

TCO
Gesamtkosten: Hardware + Strom + Personal + Abschreibung.

Alles noch einmal online

quint-games.de/hefte → eigener Name → Tag 11: Folien, Lernkarten, Selbsttest, Aufgaben und dieses Lernheft.